

第三章：线性方程组

戴一冕

南开大学 计算机学院

2025.08.26

- § 3.1 向量组与矩阵的秩
- § 3.2 线性方程组的解法
- § 3.3 线性方程组解的结构

- § 3.1 向量组与矩阵的秩
- § 3.2 线性方程组的解法
- § 3.3 线性方程组解的结构

- 向量组的线性相关与线性无关性及相关结论和定理；
- 向量、向量组的其它有关知识：等价、秩、极大线性无关组等；
- 相关问题证明；
- 线性方程组解的条件及相关结论；
- 求 (讨论) 线性方程组的解。

定义： n 维向量

n 个有次序的数 $a_1, a_2, \dots, a_n$ 所组成的数组称为 **n 维向量**，这 n 个数称为该向量的 **分量**。

几何视角

- 二维向量：平面中的点或箭头
- 三维向量：空间中的点或箭头
- n 维向量：高维空间的抽象表示

历史注记

- 向量概念源于物理学（力、速度）
- 19 世纪由吉布斯、亥维赛等数学化
- 现代线性代数中广泛使用

Python 代码实现

```
import numpy as np
vec = np.array([1, 2, 3]) # 创建 3 维向量
print("向量:", vec)
```

n 维向量可以写成行向量或列向量，对应行矩阵或列矩阵：

$$\alpha = (a_1, a_2, \dots, a_n) \quad (\text{行向量})$$

$$\beta = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix} \quad (\text{列向量})$$

注意

行向量和列向量按照矩阵运算法则进行运算，但在机器学习中常使用行向量表示样本特征。

Python 创建

```
row_vec = np.array([1, 2, 3])  
# 行向量  
col_vec = np.array  
([[1], [2], [3]]) # 列向量
```

矩阵的列向量组

向量组：若干个同维数列向量（或行向量）所组成的集合。

矩阵 $A = (a_{ij})_{m \times n}$ 有 n 个 m 维列向量：

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix} = (\alpha_1, \alpha_2, \dots, \alpha_n)$$

其中 $\alpha_j = \begin{pmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{mj} \end{pmatrix}$ 是第 j 个列向量。

几何意义

列向量组张成矩阵的列空间，表示所有可能的线性组合（生成子空间）。

Python 示例

```
A = np.array([[1,2,3],[4,5,6]])  
col_vectors = [ A[:, i] for i in range(A.shape[1]) ]
```

矩阵的行向量组

矩阵 $A = (a_{ij})_{m \times n}$ 有 m 个 n 维行向量：

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix} = \begin{pmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_m \end{pmatrix}$$

其中 $\alpha_i = (a_{i1}, a_{i2}, \dots, a_{in})$ 是第 i 个行向量。

AI 应用

在自然语言处理中，行向量常表示词嵌入（Word2Vec）。

Python 提取

```
row_vectors = [A[i, :]  
for i in range(A.shape[0])]
```


反之，由有限个向量所组成的向量组可以构成一个矩阵。

列向量组构成矩阵

m 个 n 维列向量 $\alpha_1, \alpha_2, \dots, \alpha_m$ 构成 $n \times m$ 矩阵：

$$A = (\alpha_1, \alpha_2, \dots, \alpha_m)$$

行向量组构成矩阵

m 个 n 维行向量 $\beta_1, \beta_2, \dots, \beta_m$ 构成 $m \times n$ 矩阵：

$$B = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_m \end{pmatrix}$$

历史注记

这种对应关系是矩阵理论的基础，由凯莱在 1858 年系统化。

线性方程组的向量表示

对于线性方程组：

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n = b_m \end{cases}$$

可以表示为向量形式：

$$x_1 \alpha_1 + x_2 \alpha_2 + \cdots + x_n \alpha_n = \beta$$

其中 α_j 是系数矩阵的列向量， β 是常数项向量。

几何解释

求解方程组等价于找到一组系数，使 β 落在列向量张成的空间中。

Python 求解

```
import numpy.linalg as la
solution = la.solve(A, b) # 假设 A 为系数矩阵，b 为常数向量
```

定义：线性组合

给定向量组 $A: \alpha_1, \alpha_2, \dots, \alpha_m$ ，对于任何一组数 $k_1, k_2, \dots, k_m$ ，称

$$k_1 \alpha_1 + k_2 \alpha_2 + \dots + k_m \alpha_m$$

为向量组 A 的一个**线性组合**，数 $k_1, \dots, k_m$ 称为系数。

定义：线性表示

若存在一组数 $\lambda_1, \dots, \lambda_m$ 使得

$$\beta = \lambda_1 \alpha_1 + \lambda_2 \alpha_2 + \dots + \lambda_m \alpha_m$$

则称向量 β 能由向量组 A **线性表示**，等价于方程组 $x_1 \alpha_1 + \dots + x_m \alpha_m = \beta$ 有解。

AI 应用

在神经网络中，输出层通常是输入特征的线性组合。

线性表示与等价的性质

- **零向量**：是任何向量组的线性组合。
- **等价性**：具有反身性、对称性、传递性。
 - 若 A 能由 B 线性表示， B 能由 C 线性表示，则 A 能由 C 线性表示。
- **标准基向量**： $e_1 = (1, 0, \dots, 0)$, $e_2 = (0, 1, \dots, 0)$, $\dots$, $e_n = (0, 0, \dots, 1)$ ，任何 n 维向量 α 都可由其线性表示。
- **初等变换**：矩阵 A 经初等行变换变成 B ，则 A 与 B 的行向量组等价；类似地，列变换对应列向量组等价。

几何视角

等价向量组张成相同的向量空间。

Python 验证

```
def are_equivalent(A, B):  
    # 检查行向量组是否等价  
    pass
```

定义：线性相关与线性无关

设向量组 $\alpha_1, \alpha_2, \dots, \alpha_s (s > 1)$ 中至少有一个向量可由组中其余 $s - 1$ 个向量线性表示，则称该向量组是线性相关的。否则称该向量组是线性无关的。

对于只含一个向量 α 的向量组：当 α 是零向量时，称它是线性相关的；否则称它是线性无关的。

几何解释

- 线性相关：向量在同一平面或直线上
- 线性无关：向量张成最大维度的空间
- 零向量：没有方向，与任何向量相关

Python 判断

```
import numpy as np
def is_linear_dependent(vectors):
    matrix = np.array(vectors).T
    rank = np.linalg.matrix_rank(matrix)
    return rank < len(vectors[0])
```

部分相关则全体相关

设 $\alpha_1, \dots, \alpha_r$ 线性相关, 则 $\alpha_1, \dots, \alpha_s$ ($s > r$) 也线性相关。

$$\alpha_1 = k_2 \alpha_2 + \dots + k_r \alpha_r + 0 \cdot \alpha_{r+1} + \dots + 0 \cdot \alpha_s$$

全体无关则部分无关

设向量组 $\alpha_1, \dots, \alpha_s$ 线性无关, 则任意子组也线性无关。

历史注记

线性相关性概念源于 19 世纪, 由格拉姆、施密特等数学家发展, 是现代线性代数的基石。

AI 应用

在特征选择中, 需要去除线性相关的特征以避免多重共线性问题。

定理 1

向量组 $\alpha_1, \alpha_2, \dots, \alpha_m$ **线性相关** $\iff$ 存在不全为零的数 $k_1, k_2, \dots, k_m$ 使得:

$$k_1 \alpha_1 + k_2 \alpha_2 + \dots + k_m \alpha_m = \mathbf{0}$$

证明思路

- 必要性: 从定义出发构造系数
- 充分性: 从系数反推表示关系
- 利用齐次线性方程组的解理论

代码验证

```
def check_linear_dependence(vectors):  
    A = np.array(vectors).T  
    # 解齐次方程组 Ax=0  
    # 返回是否有非零解
```

证明

必要性 ($\Rightarrow$)

设向量组 $\alpha_1, \dots, \alpha_m$ 线性相关, 则存在某个向量可被其余向量线性表示。不妨设

$$\alpha_m = c_1 \alpha_1 + \dots + c_{m-1} \alpha_{m-1}.$$

移项得

$$c_1 \alpha_1 + \dots + c_{m-1} \alpha_{m-1} - \alpha_m = \mathbf{0}.$$

取 $k_i = c_i$ ($i < m$), $k_m = -1$, 即得一组不全为零的系数使线性组合为零向量。

充分性 ($\Leftarrow$)

设存在不全为零的数 $k_1, \dots, k_m$ 使得

$$k_1 \alpha_1 + \dots + k_m \alpha_m = \mathbf{0}.$$

不妨设 $k_j \neq 0$, 则

$$\alpha_j = -\frac{1}{k_j} \sum_{i \neq j} k_i \alpha_i,$$

即 α_j 可被其余向量线性表示, 故向量组线性相关。



推论

向量组 $\alpha_1, \dots, \alpha_s$ **线性无关** $\iff$

$$k_1 \alpha_1 + \dots + k_s \alpha_s = \mathbf{0} \Rightarrow k_1 = \dots = k_s = 0$$

几何意义

线性无关向量组张成的空间维度等于向量个数，是最大可能的维度。

历史注记

这一等价条件由柯西首先提出，为线性空间理论奠定了基础。

AI 中的应用

在神经网络中，权重矩阵的列向量需要线性无关以保证模型的表达能力。

低维几何解释

- 两个向量：相关 $\iff$ 共线
- 三个向量：相关 $\iff$ 共面
- n 个向量：相关 $\iff$ 处于低维子空间

例 4 解析

设 α, β, γ 线性无关，则 $\xi = \alpha, \eta = \alpha + \beta, \zeta = \alpha - \beta - \gamma$ 也线性无关。
几何解释：变换后的向量仍然张成三维空间。

Python 可视化

```
import matplotlib.pyplot as plt
# 绘制向量箭头
# 用颜色区分线性相关与否
```

重要结论

对线性无关向量组进行可逆线性变换，得到的新向量组仍然线性无关。

定理 2

设 $\alpha_1, \dots, \alpha_s$ 线性无关, 而 $\alpha_1, \dots, \alpha_s, \beta$ 线性相关, 则 β 可由 $\alpha_1, \dots, \alpha_s$ 唯一线性表示。

证明思路

- 利用线性相关定义
- 反证法证明系数不为零
- 解出表示系数

代码实现

```
def unique_representation(basis, vector):  
    # 求解线性方程组  
    # 返回表示系数
```

应用意义

该定理是坐标表示的基础, 说明在任何一组基下, 向量的表示是唯一的。

证明

由题设, $\alpha_1, \dots, \alpha_s$ 线性无关, 而 $\alpha_1, \dots, \alpha_s, \beta$ 线性相关, 故存在不全为零的数 $k_1, \dots, k_s, k$ 使得

$$k_1 \alpha_1 + \dots + k_s \alpha_s + k \beta = \mathbf{0}.$$

下证 $k \neq 0$ 。若 $k = 0$, 则上式化为

$$k_1 \alpha_1 + \dots + k_s \alpha_s = \mathbf{0},$$

且 $k_1, \dots, k_s$ 不全为零, 这与 $\alpha_1, \dots, \alpha_s$ 线性无关矛盾。因此 $k \neq 0$, 于是可解出

$$\beta = -\frac{1}{k}(k_1 \alpha_1 + \dots + k_s \alpha_s),$$

即 β 可由 $\alpha_1, \dots, \alpha_s$ 线性表示。

再证唯一性。设

$$\beta = \sum_{i=1}^s x_i \alpha_i = \sum_{i=1}^s y_i \alpha_i,$$

则

$$\sum_{i=1}^s (x_i - y_i) \alpha_i = \mathbf{0}.$$

由 $\alpha_1, \dots, \alpha_s$ 线性无关得 $x_i - y_i = 0$ ($i = 1, \dots, s$), 即 $x_i = y_i$, 故表示唯一。 □

定理 3（表示唯一性）

在定理 2 的条件下， β 由 $\alpha_1, \dots, \alpha_s$ 的线性表示是唯一的。

证明方法

- 假设有两种表示
- 相减得零组合
- 利用线性无关性
- 得出系数相等

几何解释

在基向量确定的空间中，每个点有唯一的坐标表示。

历史背景

这一性质是坐标系理论的核心，源于笛卡尔的解析几何思想。

证明（表示唯一性）

设 β 有两种表示：

$$\beta = \sum_{i=1}^s x_i \alpha_i = \sum_{i=1}^s y_i \alpha_i.$$

两式相减得

$$\sum_{i=1}^s (x_i - y_i) \alpha_i = \mathbf{0}.$$

因 $\alpha_1, \dots, \alpha_s$ 线性无关，故系数必须全为零：

$$x_i - y_i = 0 \quad (\forall i) \Rightarrow x_i = y_i.$$

因此表示唯一。



定理 4

n 阶行列式 $|A| = 0 \iff A$ 的 n 个行 (列) 向量线性相关。

几何意义

- 行列式为零：向量张成的体积为零
- 线性相关：向量处于低维空间
- 两者都表示“退化”情况

Python 检测

```
def is_singular(matrix):  
    return np.linalg.det(matrix) == 0  
def are_dependent(vectors):  
    return is_singular(np.array(vectors).T)
```

应用价值

该定理提供了判断线性相关性的计算方法，是实际应用中最常用的方法。

证明（行列式与线性相关性）

必要性 ($\Rightarrow$)

若 $|A| = 0$ ，则齐次方程组 $A\mathbf{x} = \mathbf{0}$ 有非零解 $\mathbf{x} = (x_1, \dots, x_n)^T$ ，即

$$x_1 \mathbf{a}_1 + \dots + x_n \mathbf{a}_n = \mathbf{0},$$

其中 $\mathbf{a}_i$ 为 A 的列向量。因 $\mathbf{x} \neq \mathbf{0}$ ，故列向量线性相关。

充分性 ($\Leftarrow$)

若 A 的列向量线性相关，则存在不全为零的数 $x_1, \dots, x_n$ 使得上式成立，即 $A\mathbf{x} = \mathbf{0}$ 有非零解，故 $|A| = 0$ 。 □

推论体系

设向量组 A 中含有 r 个向量，向量组 B 中含有 s 个向量。

- 若 A 可由 B 表示且 $r > s$ ，则 A 线性相关
- 若 A 线性无关且可由 B 表示，则 $r \leq s$
- 任意 $n + 1$ 个 n 维向量必线性相关
- 等价线性无关向量组含有相同个数的向量

几何解释

- n 维空间最多有 n 个线性无关向量
- 这是空间维度的基本限制
- 解释了为什么需要降维处理

AI 应用

- PCA 降维：寻找最大线性无关组
- 特征选择：去除线性相关特征
- 模型正则化：避免过拟合

定义

- 向量组 A 的**加长组**：在 A 中再添加若干个向量所得到的新向量组（向量数 $\geq r$ ）。
- 向量组 A 的**截短组**：从 A 中去掉若干个向量后所剩下的新向量组（向量数 $\leq r$ ）。

基本性质

- **线性无关组的截短组仍线性无关**
- **线性相关组的加长组仍线性相关**

几何解释

- **加长**：增加约束，解空间不扩大
- **截短**：减少约束，解空间可能扩大
- 与线性方程组解理论一致

应用案例

- 机器学习：增维（加长）/删冗余（截短）
- 两种操作均保持相关性不变

提示

这一性质解释了为何在实际问题中常通过增减特征来优化模型。

定义：极大线性无关组

若向量组的一个子组**线性无关**，但将向量组中任何一个向量添到这个子组中去，得到的都是**线性相关**的子组，则称该子组为向量组的**极大线性无关组**。

几何解释

- 极大无关组张成向量组的最大维度空间
- 添加任何向量都会降低空间的“自由度”
- 零向量组没有极大无关组（零维空间）

历史注记

概念源于 19 世纪，由格拉斯曼和希尔伯特发展，是现代线性空间理论的核心。

Python 实现

```
import numpy as np
def max_independent_subset(vectors):
    matrix = np.array(vectors).T
    # 使用 QR 分解或 SVD 寻找极大无关组
    return basis_vectors
```

关键性质

- 极大无关组可能不唯一，但所有极大无关组**等价**
- 向量组中任何向量都可由其极大无关组**线性表示**
- 线性无关向量组的极大无关组是其自身

例：多组极大无关组

$$\begin{aligned}\alpha_1 &= (1, 0, 1, 2), \\ \alpha_2 &= (0, 1, 0, -1), \\ \alpha_3 &= (1, 1, 1, 1)\end{aligned}$$

- $\{\alpha_1, \alpha_2\}, \{\alpha_1, \alpha_3\}, \{\alpha_2, \alpha_3\}$
都是极大无关组
- 张成的都是二维平面

定理

一个向量组的所有极大无关组含有**相同数量**的向量

AI 应用

在推荐系统中，极大无关组对应核心特征，用于降维和去冗余。

定义：秩

向量组的极大线性无关组所含向量的个数，称为**向量组的秩**。零向量组的秩定义为 0。

几何意义

- 秩 = 向量组张成空间的维度
- 秩是向量组的“信息容量”度量
- 零秩对应零维空间（一个点）

重要结论

- 任何 $r + 1$ 个向量必线性相关
- 线性无关子组最多含 r 个向量
- 任意 r 个线性无关向量是极大无关组

Python 计算

```
def vector_rank(vectors):  
    return np.linalg.matrix_rank(np.array(vectors).T)
```

核心概念

- 线性相关/无关：几何视角（共面性）
- 极大无关组：空间的“基骨架”
- 秩：空间的维度度量

历史脉络

秩的概念由弗罗贝尼乌斯在 19 世纪末系统化，成为矩阵理论的核心。

AI 前沿应用

- 主成分分析 (PCA)：寻找数据集的极大无关组
- 推荐系统：利用秩降低特征维度
- 神经网络：权重矩阵的秩影响模型容量

练习

证明：等价的向量组具有相同的秩。提示：利用极大无关组的等价性和唯一数量性质。

练习证明

命题：等价的向量组具有相同的秩。

练习证明

命题：等价的向量组具有相同的秩。

证明：设向量组 S_1 与 S_2 等价（即它们可互相线性表示），记

$$r_1 = \text{rank}(S_1), \quad r_2 = \text{rank}(S_2).$$

取 S_1 的一个极大无关组 A ，则 $|A| = r_1$ 且 A 可表示 S_1 ；由等价性， S_1 又可表示 S_2 ，故 A 也可表示 S_2 。因此 A 是 S_2 的一个线性无关生成子集，从而

$$r_1 \leq r_2.$$

同理，取 S_2 的极大无关组 B 可得 $r_2 \leq r_1$ 。于是 $r_1 = r_2$ ，即二者秩相同。 □

定义

- **行秩**: 行向量组的秩
- **列秩**: 列向量组的秩
- **子式**: 取 k 行 k 列构成的 k 阶行列式

几何意义

- 秩 = 线性变换后空间的维度
- 秩 = 矩阵的“信息密度”
- 满秩矩阵保持空间维度

历史注记

秩的统一定义由克罗内克和弗罗贝尼乌斯完成，解决了早期行秩列秩分离的问题。

Python 计算

```
import numpy as np
A = np.array([[1,2],[3,4]])
rank = np.linalg.matrix_rank(A)
```

定理

矩阵的秩 = 最高阶非零子式的阶数

证明思路

- 存在 r 阶非零子式 $\rightarrow$ 存在 r 个线性无关行
- 所有 $r+1$ 阶子式为零 $\rightarrow$ 其他行可由这 r 行表示
- 故行秩 = r

几何解释

- 非零子式对应线性无关的向量组
- 最高阶子式确定空间维度
- 子式为零表示线性相关

AI 应用

在图像处理中，矩阵秩反映图像的复杂度和信息量，用于图像压缩。

证明

设 $A \in \mathbb{R}^{m \times n}$, 记其行向量组为 $\mathbf{a}_1, \dots, \mathbf{a}_m$ 。令

$$r = \max\{k : \text{存在 } k \text{ 阶子式} \neq 0\}.$$

Step 1. 存在 r 阶非零子式 $\Rightarrow$ 行秩 $\geq r$ 。不妨设左上角 $r \times r$ 子式

$$D = \det[A_{ij}]_{1 \leq i, j \leq r} \neq 0.$$

则对应的 r 个行向量 $\mathbf{a}'_1, \dots, \mathbf{a}'_r \in \mathbb{R}^r$ 线性无关, 从而它们的零扩张 $\mathbf{a}_1, \dots, \mathbf{a}_r \in \mathbb{R}^n$ 也线性无关, 故行秩 $\geq r$ 。

Step 2. 所有 $r+1$ 阶子式为零 $\Rightarrow$ 行秩 $\leq r$ 。任取 $r+1$ 行 $i_1 < \dots < i_{r+1}$ 及任意 $r+1$ 列 $j_1 < \dots < j_{r+1}$, 由条件

$$\det[A_{i_k j_l}]_{k, l=1}^{r+1} = 0.$$

故这 $r+1$ 个向量在 $\mathbb{R}^{r+1}$ 中线性相关; 由于列任意, 可推出原 $r+1$ 行向量 $\mathbf{a}_{i_1}, \dots, \mathbf{a}_{i_{r+1}}$ 在 $\mathbb{R}^n$ 中线性相关。于是任意 $r+1$ 行皆相关, 行秩 $\leq r$ 。
结合两步得行秩 $= r$; 同理列秩亦 $= r$, 故 $\text{rank}(A) = r$ 。 □

基本定理

- 行秩 = 列秩 = 最高阶非零子式的阶数
- $r(A) = r(A^T)$
- 存在 r 阶非零子式, 所有 $r + 1$ 阶子式为零

满秩矩阵

- n 阶方阵秩为 $n \Leftrightarrow$ 可逆
- 保持空间维度不变
- 对应双射线性变换

降秩矩阵

- 秩 $< n \Leftrightarrow$ 奇异矩阵
- 压缩空间维度
- 有非平凡零空间

证明：行秩 = 列秩

设 $A \in \mathbb{F}^{m \times n}$, 记其行空间为 $\mathcal{R}$, 列空间为 $\mathcal{C}$ 。令 $r = \dim \mathcal{R}$ (行秩), $s = \dim \mathcal{C}$ (列秩)。目标证 $r = s$ 。

Step 1. 构造同构。定义映射

$$\varphi : \mathcal{R} \rightarrow \mathcal{C}, \quad \varphi(\mathbf{x}) = A\mathbf{x}.$$

显然 φ 线性且满射到 $\mathcal{C}$ 。

Step 2. 计算核。 $\ker \varphi = \{\mathbf{x} \in \mathcal{R} \mid A\mathbf{x} = \mathbf{0}\}$ 。但 $\mathbf{x}$ 本身属于行空间, 故可写 $\mathbf{x} = \mathbf{a}^T \mathbf{c}$ 对某 $\mathbf{c} \in \mathbb{F}^r$ 。于是 $A\mathbf{x} = A\mathbf{a}^T \mathbf{c} = \mathbf{0}$ 。由于 $A\mathbf{a}^T$ 为 $m \times m$ 半正定矩阵, 其零空间维数

$$\dim \ker(A\mathbf{a}^T) = m - \text{rank}(A\mathbf{a}^T) = m - s.$$

然而 $\mathbf{x}$ 已限定在行空间 (维数 r), 故

$$\dim \ker \varphi = \dim(\mathcal{R} \cap \ker A) = r - s.$$

Step 3. 维数公式。由线性映射维数公式

$$\dim \mathcal{R} = \dim \text{Im } \varphi + \dim \ker \varphi \quad \Rightarrow \quad r = s + (r - s),$$

等式恒成立, 但已显式给出 $\dim \ker \varphi = r - s$ 。为使映射良定义且满射, 必须 $\dim \ker \varphi = 0$, 故 $r = s$ 。因此行秩等于列秩。 $\square$

$$\text{例 1: } A = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 3 & 5 \\ 4 & 7 & -1 \end{pmatrix}$$

$$\text{例 2: } B = \begin{pmatrix} 1 & 3 & -2 & 2 \\ 0 & 2 & 1 & -3 \\ 2 & 0 & -1 & 5 \end{pmatrix}$$

例 1: $A = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 3 & 5 \\ 4 & 7 & -1 \end{pmatrix}$

- 二阶子式 $\begin{vmatrix} 1 & 2 \\ 2 & 3 \end{vmatrix} = -1 \neq 0 \rightarrow r(A) \geq 2$
- 三阶子式 $|A| = 12 \neq 0 \rightarrow r(A) = 3$
- 故 $r(A) = 3$

例 2: $B = \begin{pmatrix} 1 & 3 & -2 & 2 \\ 0 & 2 & 1 & -3 \\ 2 & 0 & -1 & 5 \end{pmatrix}$

- 二阶子式 $\begin{vmatrix} 1 & 3 \\ 0 & 2 \end{vmatrix} = 2 \neq 0 \rightarrow r(B) \geq 2$
- 三阶子式 $\begin{vmatrix} 1 & 3 & -2 \\ 0 & 2 & 1 \\ 2 & 0 & -1 \end{vmatrix} = 10 \neq 0 \rightarrow r(B) = 3$

Python 验证

```
print(np.linalg.matrix_rank(A)) # 输出 2  
print(np.linalg.matrix_rank(B)) # 输出 3
```

关键性质

- AB 的行向量是 B 行向量的线性组合
- AB 的列向量是 A 列向量的线性组合
- 组合不增加秩: $r(AB) \leq \min(r(A), r(B))$

几何解释

- 矩阵乘法是线性变换的复合
- 复合变换的像空间维度不会超过原变换
- 秩降对应信息损失

AI 应用

- 神经网络中, 矩阵乘积的秩影响模型表达能力
- 低秩近似用于模型压缩
- 推荐系统中的矩阵补全

历史意义

该性质由西尔维斯特发现, 揭示了线性变换复合的本质特性。

证明: $r(AB) \leq \min\{r(A), r(B)\}$

设 $A \in \mathbb{F}^{m \times n}$, $B \in \mathbb{F}^{n \times p}$, 记 $C = AB \in \mathbb{F}^{m \times p}$.

Step 1. 列空间视角。把 B 按列分块: $B = [\mathbf{b}_1 \ \dots \ \mathbf{b}_p]$, 则

$$C = [A\mathbf{b}_1 \ \dots \ A\mathbf{b}_p].$$

每一列 $A\mathbf{b}_j$ 都属于 A 的列空间 $\text{Col}(A)$, 故

$$\text{Col}(C) \subseteq \text{Col}(A) \implies r(C) = \dim \text{Col}(C) \leq \dim \text{Col}(A) = r(A).$$

证明: $r(AB) \leq \min\{r(A), r(B)\}$

Step 2. 行空间视角。把 A 按行分块: $A = \begin{bmatrix} \mathbf{a}_1 \\ \vdots \\ \mathbf{a}_m \end{bmatrix}$, 则

$$C = \begin{bmatrix} \mathbf{a}_1 B \\ \vdots \\ \mathbf{a}_m B \end{bmatrix}.$$

每一行 $\mathbf{a}_i B$ 都属于 B 的行空间 $\text{Row}(B)$, 故

$$\text{Row}(C) \subseteq \text{Row}(B) \Rightarrow r(C) = \dim \text{Row}(C) \leq \dim \text{Row}(B) = r(B).$$

结合两步得

$$r(AB) \leq r(A) \quad \text{且} \quad r(AB) \leq r(B),$$

因此 $r(AB) \leq \min\{r(A), r(B)\}$.



推论 1：可逆矩阵保持秩

设 A 为 n 阶可逆矩阵， P 为 $m \times n$ 矩阵， Q 为 $n \times s$ 矩阵，则

$$r(PA) = r(P), \quad r(AQ) = r(Q)$$

可逆矩阵乘法不改变矩阵的秩。

几何解释

- 可逆变换是双射，保持空间维度
- 像空间的维度等于原空间维度
- 可逆矩阵是“维度保持者”

证明思路

- $r(AQ) \leq r(Q)$ (矩阵乘积性质)
- $Q = A^{-1}(AQ) \rightarrow r(Q) \leq r(AQ)$
- 故 $r(AQ) = r(Q)$

推论 2：初等变换保秩

初等变换不改变矩阵的秩。应用：化为行阶梯形，非零行数即为秩。

证明：可逆矩阵乘法保持秩

设 $A \in \mathbb{F}^{n \times n}$ 可逆, $P \in \mathbb{F}^{m \times n}$, $Q \in \mathbb{F}^{n \times s}$ 。

(1) 证 $r(PA) = r(P)$ 。一方面, 由矩阵乘积秩不等式得

$$r(PA) \leq r(P).$$

另一方面, 因 A 可逆, 可写

$$P = (PA)A^{-1}.$$

再次利用乘积秩不等式:

$$r(P) = r((PA)A^{-1}) \leq r(PA).$$

结合两段不等式得

$$r(PA) = r(P).$$

证明：可逆矩阵乘法保持秩

(2) 证 $r(AQ) = r(Q)$ 。同理，先有

$$r(AQ) \leq r(Q).$$

又因

$$Q = A^{-1}(AQ),$$

故

$$r(Q) = r(A^{-1}(AQ)) \leq r(AQ).$$

于是

$$r(AQ) = r(Q). \quad \square$$

例 3：求矩阵秩

$$A = \begin{pmatrix} 2 & 8 & -1 & -1 & -2 \\ 1 & 4 & 2 & 1 & 0 \\ 1 & 4 & -1 & 0 & 2 \\ 0 & 0 & 1 & 1 & 2 \end{pmatrix}$$

例 3：求矩阵秩

$$A = \begin{pmatrix} 2 & 8 & -1 & -1 & -2 \\ 1 & 4 & 2 & 1 & 0 \\ 1 & 4 & -1 & 0 & 2 \\ 0 & 0 & 1 & 1 & 2 \end{pmatrix}$$

行变换过程

$$A \xrightarrow{r_1 \leftrightarrow r_2} \begin{pmatrix} 1 & 4 & 2 & 1 & 0 \\ 2 & 8 & -1 & -1 & -2 \\ 1 & 4 & -1 & 0 & 2 \\ 0 & 0 & 1 & 1 & 2 \end{pmatrix}$$

$$\xrightarrow{\substack{r_2 \rightarrow r_2 - 2r_1 \\ r_3 \rightarrow r_3 - r_1}} \begin{pmatrix} 1 & 4 & 2 & 1 & 0 \\ 0 & 0 & -5 & -3 & -2 \\ 0 & 0 & -3 & -1 & 2 \\ 0 & 0 & 1 & 1 & 2 \end{pmatrix}$$

续

$$\xrightarrow{r_2 \leftrightarrow r_4} \begin{pmatrix} 1 & 4 & 2 & 1 & 0 \\ 0 & 0 & 1 & 1 & 2 \\ 0 & 0 & -3 & -1 & 2 \\ 0 & 0 & -5 & -3 & -2 \end{pmatrix}$$

$$\xrightarrow{\substack{r_3 \rightarrow r_3 + 3r_2 \\ r_4 \rightarrow r_4 + 5r_2}} \begin{pmatrix} 1 & 4 & 2 & 1 & 0 \\ 0 & 0 & 1 & 1 & 2 \\ 0 & 0 & 0 & 2 & 8 \\ 0 & 0 & 0 & 2 & 8 \end{pmatrix}$$

最终形式

$$\xrightarrow{r_4 \rightarrow r_4 - r_3} \begin{pmatrix} 1 & 4 & 2 & 1 & 0 \\ 0 & 0 & 1 & 1 & 2 \\ 0 & 0 & 0 & 2 & 8 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix} \text{ 有 3 个非零行, 故 } r(A) = 3.$$

定理：矩阵标准形

非零矩阵 $A_{m \times n}$ 的秩为 $r \iff$ 存在可逆矩阵 P_m 和 Q_n 使得

$$PAQ = \begin{pmatrix} E_r & O \\ O & O \end{pmatrix}$$

其中 E_r 是 r 阶单位阵。

初等变换保线性关系

初等行变换不改变列向量组的线性关系。

解释：变换前后齐次方程组解集相同。

历史注记

矩阵标准形理论由弗罗贝尼乌斯完善，是线性代数分类理论的基础。

AI 应用

在数据预处理中，保持线性关系意味着保持特征间的相关性结构。

证明：矩阵标准形定理

必要性 ($\Rightarrow$) 设 $r(A) = r$ 。1. 对 A 施行初等行变换（对应左乘可逆矩阵 P_1 ）化为行阶梯形 P_1A ，其非零行数为 r 。2. 再对 P_1A 施行初等列变换（对应右乘可逆矩阵 Q_1 ）可将前 r 个主元列化为标准基向量，得到

$$P_1AQ_1 = \begin{pmatrix} E_r & * \\ O & * \end{pmatrix}.$$

3. 继续用列变换消去右上角 “*” 块，最终得到

$$PAQ = \begin{pmatrix} E_r & O \\ O & O \end{pmatrix}, \quad \text{其中 } P = P_1, Q = Q_1 \cdots Q_k.$$

充分性 ($\Leftarrow$) 若存在可逆 P, Q 使

$$PAQ = \begin{pmatrix} E_r & O \\ O & O \end{pmatrix},$$

则右端矩阵的秩显然为 r 。由于可逆乘法不改变秩，故

$$r(A) = r(PAQ) = r. \quad \square$$

算法步骤

1. 以向量组为**列向量**构造矩阵 A
2. 对 A 施行初等**行**变换化为行简化阶梯形 B
3. B 中主元所在列对应 A 中的列向量构成极大无关组
4. B 中的线性关系直接反映 A 中的线性关系

几何意义

- 行变换相当于基变换
- 主元列对应线性无关的“基向量”
- 非主元列可由主元列线性表示

Python 实现

```
def max_indep_set(vectors):  
    A = np.column_stack(vectors)  
    # 行简化阶梯形  
    # 找主元列  
    return basis_indices
```

例 4

$$\alpha_1 = (1, 0, 2, 1), \alpha_2 = (1, 2, 0, 1), \alpha_3 = (2, 1, 3, 0), \\ \alpha_4 = (2, 5, -1, 4), \alpha_5 = (1, -1, 3, -1)$$

例 4

$$\alpha_1 = (1, 0, 2, 1), \alpha_2 = (1, 2, 0, 1), \alpha_3 = (2, 1, 3, 0), \\ \alpha_4 = (2, 5, -1, 4), \alpha_5 = (1, -1, 3, -1)$$

构造矩阵

$$A = (\alpha_1, \alpha_2, \alpha_3, \alpha_4, \alpha_5)$$

$$= \begin{pmatrix} 1 & 1 & 2 & 2 & 1 \\ 0 & 2 & 1 & 5 & -1 \\ 2 & 0 & 3 & -1 & 3 \\ 1 & 1 & 0 & 4 & -1 \end{pmatrix}$$

行简化形式

$$B = \begin{pmatrix} 1 & 0 & 0 & -1 & 0 \\ 0 & 1 & 0 & 3 & -1 \\ 0 & 0 & 1 & -1 & 1 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

结果分析

- 主元在第 1,2,3 列 $\Rightarrow \{\alpha_1, \alpha_2, \alpha_3\}$ 是极大无关组
- $\alpha_4 = -\alpha_1 + 3\alpha_2 - \alpha_3$
- $\alpha_5 = -\alpha_2 + \alpha_3$

核心概念

- 矩阵秩：行秩 = 列秩 = 最高非零子式阶数
- 极大无关组：向量组的“基骨架”
- 秩的性质：可逆乘法保秩、初等变换保秩

计算方法

- 子式法：找最高阶非零子式
- 初等变换法：化为行阶梯形
- 极大无关组：列向量 + 行变换

历史意义

秩理论完善于 19 世纪末，为现代线性代数奠定了基础，是矩阵分析的核心工具。

几何视角

- 秩 = 空间维度
- 极大无关组 = 空间基向量
- 初等变换 = 基变换

AI 应用

- 特征选择：找极大无关组
- 模型压缩：低秩近似
- 数据降维：保持关键线性关系

Q&A

- § 3.1 向量组与矩阵的秩
- **§ 3.2 线性方程组的解法**
- § 3.3 线性方程组解的结构

线性方程组

$$\begin{cases} a_{11}x_1 + \cdots + a_{1n}x_n = b_1 \\ \vdots \\ a_{m1}x_1 + \cdots + a_{mn}x_n = b_m \end{cases}$$

矩阵形式

$$Ax = b$$

- A : 系数矩阵
- b : 常数项向量
- x : 未知向量

历史注记

- 最早见于《九章算术》(公元前 100 年)
- 高斯消元法由高斯在 19 世纪系统化
- 矩阵表示由凯莱在 1858 年引入

几何视角

- 齐次: $b = 0$, 解空间过原点
- 非齐次: $b \neq 0$, 解空间平移
- 解向量: 解空间的点坐标

Python 表示

```
import numpy as np
A = np.array([[a11, ..., a1n],
              ..., [am1, ..., amn]])
b = np.array([b1, ..., bm])
```


定理 1：解的存在条件

非齐次线性方程组 $Ax = b$ 有解 $\iff$

$$\text{rank}(A) = \text{rank}(B)$$

其中 $B = (A \mid b)$ 是增广矩阵。

几何解释

- b 在 A 的列空间中
- 解存在 $\iff b$ 可被 A 的列向量线性表示
- 秩相等保证维度一致

AI 应用

在机器学习中，该条件判断线性模型是否可解：

- 线性回归的参数求解
- 神经网络权重优化
- 推荐系统的矩阵分解

Python 验证

```
def has_solution(A, b):  
    aug = np.column_stack((A, b))  
    return np.linalg.matrix_rank(A) ==  
           np.linalg.matrix_rank(aug)
```

定理 1 证明：必要性

目标

证明：若 $Ax = b$ 有解，则 $\text{rank}(A) = \text{rank}(A | b)$ 。

Step 1. 解的存在 $\Rightarrow b \in \text{Col}(A)$

设存在 $\mathbf{x}_0 \in \mathbb{F}^n$ 使得

$$A\mathbf{x}_0 = \mathbf{b}.$$

将 A 按列分块 $A = [\mathbf{a}_1 \ \dots \ \mathbf{a}_n]$ ，则

$$\mathbf{b} = x_{0,1}\mathbf{a}_1 + \dots + x_{0,n}\mathbf{a}_n \in \text{Col}(A).$$

矩阵 A 的列空间 $\text{Col}(A)$ 定义： A 的所有列向量线性组合构成的集合

$$\text{Col}(A) \triangleq \left\{ c_1 a_1 + c_2 a_2 + \dots + c_n a_n \mid c_1, c_2, \dots, c_n \in \mathbb{R}, A = [a_1 \ a_2 \ \dots \ a_n] \in \mathbb{R}^{m \times n} \right\}$$

Step 2. 列空间相等

由于 $\mathbf{b}$ 已被 A 的列线性表示，增广矩阵 $(A | \mathbf{b})$ 的列空间与 A 的列空间完全一致：

$$\text{Col}(A | \mathbf{b}) = \text{Col}(A).$$

定理 1 证明：充分性

目标

证明：若 $\text{rank}(A) = \text{rank}(A \mid \mathbf{b})$ ，则 $A\mathbf{x} = \mathbf{b}$ 有解。

Step 1. 提取非零子式

设 $r = \text{rank}(A) = \text{rank}(A \mid \mathbf{b})$ 。取 A 中一个 $r \times r$ 非零子式 Δ ，不妨设位于前 r 行与前 r 列：

$$\Delta = \det[A_{ij}]_{1 \leq i, j \leq r} \neq 0.$$

Step 2. 构造简化系统

把原系统 $A\mathbf{x} = \mathbf{b}$ 的前 r 个方程保留，其余舍去（舍去的方程是冗余的），得到

$$A'\mathbf{x} = \mathbf{b}', \quad A' \in \mathbb{F}^{r \times n}, \mathbf{b}' \in \mathbb{F}^r.$$

由于 $\text{rank}(A \mid \mathbf{b}) = r$ ，增广矩阵 $(A' \mid \mathbf{b}')$ 的秩仍为 r ，故该子系统与原系统同解。

Cramer 法则落地

将 A' 进一步按主元列划分为可逆块 $A'_1 \in \mathbb{F}^{r \times r}$ ，则

$$\mathbf{x}_1 = A_1'^{-1} \mathbf{b}'$$

，自由变量取 0。即得一特解 $\mathbf{x}_0$ 。

Step 3. 回代验证

把求得的 $\mathbf{x}_0$ 代入原系统：

$$A\mathbf{x}_0 = \mathbf{b} \implies \text{解存在。} \quad \square$$

定理 2：解的分类

设 $r = \text{rank}(A)$, n 为未知数个数：

- $\text{rank}(A) \neq \text{rank}(B)$: 无解
- $\text{rank}(A) = \text{rank}(B) = n$: 唯一解
- $\text{rank}(A) = \text{rank}(B) < n$: 无穷多解

几何解释

- 唯一解：超平面交于一点
- 无穷解：超平面交于线性流形
- 无解：超平面不相交

自由变量

当 $r < n$ 时：

- $n - r$ 个自由变量
- 解空间维度 = $n - r$
- 通解 = 特解 + 齐次通解

AI 应用

在深度学习中，无穷多解对应模型的过参数化，需要正则化约束解空间。

定理 2 证明 (I): 无解情形

Step 1. 列空间维度增加

由于增添列 $\mathbf{b}$ 后秩严格增大, 有

$$\text{Col}(A) \subsetneq \text{Col}(A \mid \mathbf{b}), \quad \dim \text{Col}(A \mid \mathbf{b}) = \dim \text{Col}(A) + 1.$$

这表明

$$\mathbf{b} \notin \text{Col}(A).$$

Step 2. 方程矛盾

若硬性地把 $\mathbf{b}$ 写成 A 列的线性组合, 则会出现

$$\sum_{j=1}^n x_j \mathbf{a}_j - \mathbf{b} = \mathbf{0} \quad \text{且系数不可能全为零,}$$

即增广矩阵的行最简形会出现形如

$$[0 \ \dots \ 0 \mid c], \quad c \neq 0$$

的矛盾行, 故方程组无解。



Step 1. 列满秩

$r = n$ 表明 A 的 n 个列向量线性无关, 即

$$\text{rank}(A) = \text{列数} = \text{未知数个数}.$$

因此齐次方程

$$Az = \mathbf{0}$$

只有零解 $\mathbf{z} = \mathbf{0}$ 。

Step 2. 差分法证唯一

设 $\mathbf{x}_1, \mathbf{x}_2$ 均满足 $A\mathbf{x}_i = \mathbf{b}$ 。令 $\mathbf{z} = \mathbf{x}_1 - \mathbf{x}_2$, 则

$$A\mathbf{z} = A(\mathbf{x}_1 - \mathbf{x}_2) = \mathbf{b} - \mathbf{b} = \mathbf{0}.$$

由列满秩得 $\mathbf{z} = \mathbf{0}$, 故 $\mathbf{x}_1 = \mathbf{x}_2$, 解唯一。



Step 1. 齐次解空间非零

$r < n$ 表明 A 的列向量线性相关, 故

$$\dim \ker A = n - r \geq 1.$$

取 $\ker A$ 的一组基 $\{\xi_1, \dots, \xi_{n-r}\}$, 则对任意实参数 t_i ,

$$A\left(\sum_{i=1}^{n-r} t_i \xi_i\right) = \mathbf{0}.$$

Step 2. 仿射解空间

固定一特解 $\mathbf{x}_p$ 满足 $A\mathbf{x}_p = \mathbf{b}$ 。对任意解 $\mathbf{x}$, 令 $\mathbf{z} = \mathbf{x} - \mathbf{x}_p \in \ker A$, 于是

$$\mathbf{x} = \mathbf{x}_p + \sum_{i=1}^{n-r} t_i \xi_i, \quad t_i \in \mathbb{F}.$$

参数 t_i 可连续取值, 故解无穷。



初等行变换

- 行倍乘: $r_i \leftarrow k \cdot r_i$
- 行交换: $r_i \leftrightarrow r_j$
- 行加减: $r_i \leftarrow r_i + k \cdot r_j$

保持解集不变

求解流程

1. 构造增广矩阵 $B = (A \mid b)$
2. 行变换化为行阶梯形
3. 判断解的存在性
4. 若存在解，化为行简化阶梯形
5. 读取解（唯一解或通解）

历史发展

- 中国古代“方程术”（公元前 100 年）
- 高斯系统化（19 世纪初）
- 现代：LU 分解、QR 分解等变体

Python 实现

```
from scipy.linalg import lu_factor
# LU 分解求解
lu, piv = lu_factor(A)
x = lu_solve((lu, piv), b)
```

行简化阶梯形

通过初等行变换化为：

$$\begin{pmatrix} 1 & 0 & \cdots & 0 & c_{1,r+1} & \cdots & c_{1n} & d_1 \\ 0 & 1 & \cdots & 0 & c_{2,r+1} & \cdots & c_{2n} & d_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & c_{r,r+1} & \cdots & c_{rn} & d_r \\ 0 & 0 & \cdots & 0 & 0 & \cdots & 0 & 0 \\ \vdots & \vdots & & \vdots & \vdots & & \vdots & \vdots \\ 0 & 0 & \cdots & 0 & 0 & \cdots & 0 & 0 \end{pmatrix}$$

解的结构

- 唯一解： $x_i = d_i$
- 无穷解： $x_i = d_i + \sum c_{ij}t_j$
- 自由变量： $t_j = x_{r+j}$

几何意义

- 特解：解空间的一个基点
- 自由变量：解空间的基向量
- 通解：仿射空间参数化

AI 应用

在优化问题中，自由变量对应模型的灵活性，需要正则化约束。

通解的一般形式

当 $r < n$ 时, 令自由变量 $x_{r+1}, \dots, x_n$ 为任意常数:

$$\begin{cases} x_1 = d_1 - c_{1,r+1}x_{r+1} - \dots - c_{1n}x_n \\ \vdots \\ x_r = d_r - c_{r,r+1}x_{r+1} - \dots - c_{rn}x_n \\ x_{r+1} = x_{r+1} \\ \vdots \\ x_n = x_n \end{cases}$$

向量形式

$$X = X_0 + c_1 \xi_1 + c_2 \xi_2 + \dots + c_{n-r} \xi_{n-r}$$

- X_0 : 特解 (非齐次)
- ξ_i : 齐次解基向量
- c_i : 任意常数

几何解释

- 特解: 解空间的一个点
- 齐次解: 解空间的方向向量
- 通解: 仿射空间参数化

Python 实现

```
def general_solution(A, b):  
    # 求特解和齐次基础解系  
    return particular_sol, null_basis
```

例 1: 线性方程组求解

问题

求解:

$$\begin{cases} x_1 - x_2 - x_3 + x_4 = 0 \\ x_1 - x_2 + x_3 - 3x_4 = 1 \\ x_1 - x_2 - 2x_3 + 3x_4 = -1/2 \end{cases}$$

例 1: 线性方程组求解

问题

求解:

$$\begin{cases} x_1 - x_2 - x_3 + x_4 = 0 \\ x_1 - x_2 + x_3 - 3x_4 = 1 \\ x_1 - x_2 - 2x_3 + 3x_4 = -1/2 \end{cases}$$

增广矩阵变换

$$B = \begin{pmatrix} 1 & -1 & -1 & 1 & 0 \\ 1 & -1 & 1 & -3 & 1 \\ 1 & -1 & -2 & 3 & -1/2 \end{pmatrix}$$

→ 行阶梯形 →

$$B_1 = \begin{pmatrix} 1 & -1 & 0 & -1 & 1/2 \\ 0 & 0 & 1 & -2 & 1/2 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

解的分析

- $\text{rank}(A) = \text{rank}(B) = 2$
- $n = 4, r = 2$
- 自由变量: x_2, x_4
- 无穷多解

通解表达式

$$\begin{cases} x_1 = c_1 + c_2 + 1/2 \\ x_2 = c_1 \\ x_3 = 2c_2 + 1/2 \\ x_4 = c_2 \end{cases}$$

向量形式

$$\mathbf{x} = \begin{pmatrix} 1/2 \\ 0 \\ 1/2 \\ 0 \end{pmatrix} + c_1 \begin{pmatrix} 1 \\ 1 \\ 0 \\ 0 \end{pmatrix} + c_2 \begin{pmatrix} 1 \\ 0 \\ 2 \\ 1 \end{pmatrix}$$

几何意义

- 特解: $(1/2, 0, 1/2, 0)$
- 解空间: 二维平面 (由基向量张成)
- 基向量: $(1, 1, 0, 0)$ 和 $(1, 0, 2, 1)$

问题

讨论 λ 取值对解的影响:

$$\begin{cases} x_1 + x_2 + \lambda x_3 = 1 \\ x_1 + \lambda x_2 + x_3 = \lambda \\ \lambda x_1 + x_2 + x_3 = \lambda^2 \end{cases}$$

例 2: 含参方程组的讨论

问题

讨论 λ 取值对解的影响:

$$\begin{cases} x_1 + x_2 + \lambda x_3 = 1 \\ x_1 + \lambda x_2 + x_3 = \lambda \\ \lambda x_1 + x_2 + x_3 = \lambda^2 \end{cases}$$

行列式分析

$$|A| = \begin{vmatrix} 1 & 1 & \lambda \\ 1 & \lambda & 1 \\ \lambda & 1 & 1 \end{vmatrix} = -(\lambda - 1)^2(\lambda + 2)$$

- $\lambda = 1$: 奇异矩阵
- $\lambda = -2$: 奇异矩阵
- 其他: 可逆矩阵

物理意义

- 参数变化导致系统性质改变
- 临界点: $\lambda = 1$ 和 $\lambda = -2$
- 类似相变现象

情况分析

- $\lambda = 1$: 系数矩阵奇异

$$B \rightarrow \begin{pmatrix} 1 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

$\text{rank}(A) = 1, \text{rank}(B) = 1 \rightarrow$ 无穷多解

- $\lambda = -2$: 系数矩阵奇异

$$B \rightarrow \begin{pmatrix} 1 & 1 & -2 & 1 \\ 0 & -3 & 3 & -3 \\ 0 & 0 & 0 & 4 \end{pmatrix}$$

$\text{rank}(A) = 2, \text{rank}(B) = 3 \rightarrow$ 无解

- 其他情况: 系数矩阵可逆 $\rightarrow$ 唯一解

$$x_1 = -\frac{\lambda}{\lambda + 2}, \quad x_2 = \frac{1}{\lambda + 2}, \quad x_3 = \frac{(\lambda + 1)^2}{\lambda + 2}$$

基本形式

$$A\mathbf{x} = \mathbf{0}$$

解的性质

- 必有零解: $\mathbf{x} = \mathbf{0}$
- $\text{rank}(A) = n$: 只有零解
- $\text{rank}(A) < n$: 有非零解
- 解空间是向量空间

历史注记

- 齐次方程组研究始于 18 世纪
- 欧拉、拉格朗日贡献显著
- 基础解系概念由格拉斯曼提出

AI 应用

- 神经网络中的齐次约束
- 图像处理中的零空间分析
- 控制理论中的系统稳定性

问题

求解：

$$\begin{cases} x_1 + 2x_2 + 2x_3 + x_4 = 0 \\ 2x_1 + x_2 - 2x_3 - 2x_4 = 0 \\ x_1 - x_2 - 4x_3 - 3x_4 = 0 \end{cases}$$

问题

求解：

$$\begin{cases} x_1 + 2x_2 + 2x_3 + x_4 = 0 \\ 2x_1 + x_2 - 2x_3 - 2x_4 = 0 \\ x_1 - x_2 - 4x_3 - 3x_4 = 0 \end{cases}$$

系数矩阵变换

$$A = \begin{pmatrix} 1 & 2 & 2 & 1 \\ 2 & 1 & -2 & -2 \\ 1 & -1 & -4 & -3 \end{pmatrix}$$

→ 行简化形 →

$$\begin{pmatrix} 1 & 0 & -2 & -5/3 \\ 0 & 1 & 2 & 4/3 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

解的分析

- $\text{rank}(A) = 2, n = 4$
- 自由变量: x_3, x_4
- 基础解系维度: 2

通解表达式

$$\begin{cases} x_1 = 2c_1 + \frac{5}{3}c_2 \\ x_2 = -2c_1 - \frac{4}{3}c_2 \\ x_3 = c_1 \\ x_4 = c_2 \end{cases}$$

基础解系

$$\xi_1 = \begin{pmatrix} 2 \\ -2 \\ 1 \\ 0 \end{pmatrix}, \quad \xi_2 = \begin{pmatrix} 5/3 \\ -4/3 \\ 0 \\ 1 \end{pmatrix}$$

- 线性无关
- 张成解空间
- 任意解可表示为线性组合

几何意义

- 解空间: 二维子空间
- 基础解系: 空间基向量
- 通解: 空间参数化

非齐次线性方程组 Ax

- $\text{rank}A \neq \text{rank}B \iff$ 无解
- $\text{rank}A = \text{rank}B = n \iff$
唯一解
- $\text{rank}A = \text{rank}B < n \iff$
无穷多解

齐次线性方程组 Ax

- $\text{rank}A = n \iff$ 只有零解
- $\text{rank}A < n \iff$ 有非零解

习题 1

设线性方程组的系数矩阵为 A ，增广矩阵为 B 。证明：若 A 的秩与矩阵 $M = \begin{pmatrix} A & b \\ b^T & 0 \end{pmatrix}$ 的秩相等，则该方程组有解。

证明.

我们有 $\text{rank}A \leq \text{rank}B = \text{rank}(A, b)$ 。同时，将 A 看作 M 的子矩阵，有 $\text{rank}A \leq \text{rank}M$ 。将 (A, b) 看作 M 的子矩阵，有 $\text{rank}(A, b) \leq \text{rank}M$ 。

综上， $\text{rank}A \leq \text{rank}(A, b) \leq \text{rank}M$ 。根据题设 $\text{rank}A = \text{rank}M$ ，因此必须有 $\text{rank}A = \text{rank}(A, b)$ 。故方程组有解。 $\square$

习题 2

证明方程组在特定条件下必有非零解。

- **条件 1:** 系数 a, b, c, d, e 中有两个等于-1。
- **条件 2:** 系数都不等于-1，但满足特定关系。

习题 2（条件 1）

设线性方程组系数矩阵 $A \in \mathbb{R}^{n \times n}$ 。若 a, b, c, d, e 中有两个等于 -1 ，则 $|A| = 0$ ，从而方程组必有非零解。

Step 1. 两行（或两列）相等 / 成比例

不妨设第 i 行与第 j 行对应系数均为 -1 （其余系数任意），则

$$\mathbf{r}_i = \mathbf{r}_j.$$

此时矩阵 A 出现两行完全相同，故

$$|A| = 0.$$

Step 2. 齐次方程有非零解

由 $|A| = 0$ 知 $\dim \ker A \geq 1$ ，即存在非零向量 $\mathbf{x}_0$ 使得

$$A\mathbf{x}_0 = \mathbf{0}.$$

因此原齐次线性方程组必有非零解。



习题 2 (条件 2)

设系数都不等于 -1 ，但满足特定代数关系（以 3×3 为例）：

$$A = \begin{bmatrix} a & b & c \\ d & e & f \\ g & h & i \end{bmatrix}, \quad \text{且 } a, e, i \neq -1.$$

若存在关系

$$(a+1)(e+1)(i+1) = 1 + (b+d)(c+g)(f+h),$$

则 $|A| = 0$ ，方程组必有非零解。

Step 1. 构造辅助矩阵

令

$$S = \text{diag}(a+1, e+1, i+1), \quad T = \begin{bmatrix} 0 & b & c \\ d & 0 & f \\ g & h & 0 \end{bmatrix}.$$

则 $A = S - T$ ，且 $\det S = (a+1)(e+1)(i+1) \neq 0$ 。

Step 2. 行列式计算

利用矩阵行列式引理（或直接展开）：

$$|A| = |S - T| = |S| \cdot |E - S^{-1}T|.$$

计算 $S^{-1}T$ 得

$$S^{-1}T = \begin{bmatrix} 0 & \frac{b}{a+1} & \frac{c}{a+1} \\ \frac{d}{e+1} & 0 & \frac{f}{e+1} \\ \frac{g}{i+1} & \frac{h}{i+1} & 0 \end{bmatrix}.$$

其特征多项式常数项为

$$-\frac{(b+d)(c+g)(f+h)}{(a+1)(e+1)(i+1)}.$$

由给定关系可知该常数项等于 -1 ，故

$$|E - S^{-1}T| = 0 \Rightarrow |A| = 0.$$

因此方程组必有非零解。



Q&A

- § 3.1 向量组与矩阵的秩
- § 3.2 线性方程组的解法
- **§ 3.3 线性方程组解的结构**

基本形式

$$A\mathbf{x} = \mathbf{0}$$

解集性质

- 解集构成向量空间（零空间）
- 包含零向量（平凡解）
- 对加法和数乘封闭

历史注记

- 零空间概念由格拉斯曼提出
- 希尔伯特发展无限维理论
- 现代应用广泛于工程和 AI

几何解释

解空间是 A 的零空间，表示所有被 A 映射到零向量的向量集合。

Python 表示

```
import numpy as np
# 创建系数矩阵
A = np.array([[a11, ..., a1n], ..., [am1, ..., amn]])
```

封闭性性质

- 性质 1: 若 ξ_1, ξ_2 是解, 则 $\xi_1 + \xi_2$ 也是解
- 性质 2: 若 ξ_1 是解, k 是实数, 则 $k\xi_1$ 也是解

证明思路

- $A(\xi_1 + \xi_2) = A\xi_1 + A\xi_2 = 0 + 0 = 0$
- $A(k\xi_1) = k(A\xi_1) = k \cdot 0 = 0$

几何意义

- 解空间对线性运算封闭
- 解集构成向量子空间
- 零向量是空间的原点

AI 应用

在神经网络中, 齐次方程的解空间对应权重空间的对称性, 影响模型的泛化能力。

目标

验证齐次线性方程组 $A\mathbf{x} = \mathbf{0}$ 的解集

$$\mathcal{S} = \{\xi \in \mathbb{F}^n \mid A\xi = \mathbf{0}\}$$

对向量加法与数乘封闭, 即 $\mathcal{S} \leq \mathbb{F}^n$ 是子空间。

性质 1——加法封闭

任取 $\xi_1, \xi_2 \in \mathcal{S}$, 则

$$A\xi_1 = \mathbf{0}, \quad A\xi_2 = \mathbf{0}.$$

考虑和向量 $\xi_1 + \xi_2$:

$$A(\xi_1 + \xi_2) = A\xi_1 + A\xi_2 = \mathbf{0} + \mathbf{0} = \mathbf{0}.$$

故 $\xi_1 + \xi_2 \in \mathcal{S}$ 。

性质 2——数乘封闭

任取 $\xi_1 \in \mathcal{S}$, $k \in \mathbb{F}$, 则

$$A(k\xi_1) = k(A\xi_1) = k \cdot \mathbf{0} = \mathbf{0}.$$

故 $k\xi_1 \in \mathcal{S}$ 。

零向量存在

取 $k = 0$ 得 $0 \cdot \xi_1 = \mathbf{0} \in \mathcal{S}$, 子空间定义完备。



基础解系定义

齐次线性方程组解空间的极大线性无关组，称为基础解系。

核心性质

- 基础解系线性无关
- 任何解可表示为基的线性组合
- 通解形式： $k_1X_1 + k_2X_2 + \dots + k_sX_s$

历史发展

- 基础解系概念源于 19 世纪
- 由弗罗贝尼乌斯系统化
- 是现代线性代数基石

几何视角

基础解系是解空间的“坐标系”，提供了描述所有解的标准方式。

Python 实现

```
from scipy.linalg import null_space  
basis = null_space(A) # 计算基础解系
```

构造步骤

1. 设 $r(A) = r < n$
2. 选择 $n - r$ 个自由变量
3. 令自由变量取标准基值 $(1, 0, \dots, 0), (0, 1, \dots, 0), \dots$
4. 求解得到 $n - r$ 个特解

具体形式

$$X_1 = (c_{11}, \dots, c_{1r}, 1, 0, \dots, 0)^T$$

$$X_2 = (c_{21}, \dots, c_{2r}, 0, 1, \dots, 0)^T$$

$$\vdots$$

$$X_{n-r} = (c_{n-r,1}, \dots, c_{n-r,r}, 0, \dots, 1)^T$$

几何解释

- 每个基向量对应一个“方向”
- 自由变量参数化解空间
- 标准基选择确保线性无关性

AI 应用

在数据降维中，基础解系帮助识别和移除冗余特征，提高模型效率。

定理：基础解系维度

当 $r(A) = r < n$ 时，齐次线性方程组 $Ax = 0$ 的基础解系含有 $n - r$ 个向量。

证明思路

- 解空间维度 = $n - r$
- 基础解系是解空间的基
- 故基向量个数 = $n - r$

几何意义

- r : 约束条件数量
- $n - r$: 自由度数量
- 解空间是 $n - r$ 维子空间

应用价值

该定理解释了为什么深度学习中的过参数化模型 ($n \gg r$) 有大量解，需要正则化约束。

Python 验证

```
dim = A.shape[1] - np.linalg.matrix_rank(A)
print(" 解空间维度:", dim)
```

定理重述

设 $A \in \mathbb{F}^{m \times n}$, $\text{rank}(A) = r < n$ 。则齐次方程组 $A\mathbf{x} = \mathbf{0}$ 的解空间

$$\mathcal{S} = \{\xi \in \mathbb{F}^n \mid A\xi = \mathbf{0}\}$$

维数为 $n - r$, 其任意一组基 (基础解系) 恰含 $n - r$ 个向量。

Step 1. 行最简形

对 A 施行初等行变换 (左乘可逆矩阵 P) 得行最简形

$$PA = R = [E_r \mid F] \in \mathbb{F}^{r \times n}, \quad F \in \mathbb{F}^{r \times (n-r)}.$$

方程组 $A\mathbf{x} = \mathbf{0}$ 与 $R\mathbf{x} = \mathbf{0}$ 同解。

Step 2. 自由变量

将未知数对应划分：

$$\mathbf{x} = \begin{bmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \end{bmatrix}, \quad \mathbf{x}_1 \in \mathbb{F}^r, \mathbf{x}_2 \in \mathbb{F}^{n-r}.$$

则 $R\mathbf{x} = \mathbf{0}$ 写成

$$\mathbf{x}_1 + F\mathbf{x}_2 = \mathbf{0} \Rightarrow \mathbf{x}_1 = -F\mathbf{x}_2.$$

$\mathbf{x}_2$ 可任意取值，称为自由变量，共 $n - r$ 个。

Step 3. 构造基础解系

取 $\mathbf{x}_2$ 为单位向量组 $\mathbf{e}_1, \dots, \mathbf{e}_{n-r}$ ，得到

$$\boldsymbol{\xi}_i = \begin{bmatrix} -F\mathbf{e}_i \\ \mathbf{e}_i \end{bmatrix}, \quad i = 1, \dots, n - r.$$

这些向量线性无关且张成整个 $\mathcal{S}$ ，故构成一组基，个数为 $n - r$ 。



科学计算

- 有限元分析中的刚度矩阵
- 计算流体力学中的守恒律
- 结构力学中的平衡方程

机器学习

- 神经网络的正则化
- 支持向量机的间隔最大化
- 主成分分析的降维处理

计算机视觉

- 图像处理中的滤波核设计
- 三维重建中的投影矩阵
- 相机校准中的参数估计

量子计算

- 量子态的空间结构
- 量子门操作的对称性
- 量子纠错码设计

历史意义

基础解系理论是线性代数的核心成果，为现代科学技术提供了数学基础。

问题

求解齐次线性方程组：

$$\begin{cases} x_1 + x_2 - x_3 - x_4 = 0 \\ 2x_1 - 5x_2 + 3x_3 + 2x_4 = 0 \\ 7x_1 - 7x_2 + 3x_3 + x_4 = 0 \end{cases}$$

例 1: 齐次线性方程组求解

问题

求解齐次线性方程组：

$$\begin{cases} x_1 + x_2 - x_3 - x_4 = 0 \\ 2x_1 - 5x_2 + 3x_3 + 2x_4 = 0 \\ 7x_1 - 7x_2 + 3x_3 + x_4 = 0 \end{cases}$$

系数矩阵变换

$$A = \begin{pmatrix} 1 & 1 & -1 & -1 \\ 2 & -5 & 3 & 2 \\ 7 & -7 & 3 & 1 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 0 & -2/7 & -3/7 \\ 0 & 1 & -5/7 & -4/7 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

Python 实现

```
import numpy as np
from scipy.linalg import null_space
A = np.array([[1,1,-1,-1],[2,-5,3,2],[7,-7,3,1]])
basis = null_space(A) # 计算基础解系
```

例 1: 通解与基础解系

同解方程组

$$\begin{cases} x_1 = \frac{2}{7}x_3 + \frac{3}{7}x_4 \\ x_2 = \frac{5}{7}x_3 + \frac{4}{7}x_4 \end{cases}$$

自由变量: x_3, x_4

基础解系

$$\xi_1 = \begin{pmatrix} 2/7 \\ 5/7 \\ 1 \\ 0 \end{pmatrix}, \quad \xi_2 = \begin{pmatrix} 3/7 \\ 4/7 \\ 0 \\ 1 \end{pmatrix}$$

几何意义

- 解空间: 二维平面
- 基础解系: 平面基向量
- 通解: 平面参数化

通解表达式

$$X = k_1 \xi_1 + k_2 \xi_2 \quad (k_1, k_2 \in \mathbb{R})$$

AI 应用

在神经网络中，齐次方程的解空间对应权重空间的对称性，影响模型泛化能力。

命题

证明 $AB = O$ 的充要条件是 B 的每个列向量都是 $AX = O$ 的解。

例 2: 矩阵乘积与零空间

命题

证明 $AB = O$ 的充要条件是 B 的每个列向量都是 $AX = O$ 的解。

证明思路

- 设 $B = (\beta_1, \beta_2, \dots, \beta_s)$
- $AB = (A\beta_1, A\beta_2, \dots, A\beta_s)$
- $AB = O \iff A\beta_i = 0$ 对所有 i

几何解释

- B 的列向量属于 A 的零空间
- A 将 B 的列映射到零向量
- 矩阵乘法对应线性变换复合

Python 验证

```
import numpy as np
# 生成随机矩阵验证
A = np.random.randn(3, 4)
B = null_space(A) # 获取零空间基
# 验证 AB=0
print(np.allclose(A @ B, 0))
```

例 2 证明：矩阵乘积 $AB = O$ 的充要条件

必要性 ($\Rightarrow$)

已知 $AB = O$ 。将 B 按列分块：

$$B = [\beta_1 \mid \beta_2 \mid \cdots \mid \beta_s], \quad \beta_j \in \mathbb{F}^n.$$

则

$$AB = A[\beta_1 \mid \cdots \mid \beta_s] = [A\beta_1 \mid \cdots \mid A\beta_s].$$

由 $AB = O$ 得

$$A\beta_j = \mathbf{0} \quad (\forall j = 1, \dots, s).$$

故每一列 β_j 都是 $A\mathbf{x} = \mathbf{0}$ 的解。

充分性 ($\Leftarrow$)

已知 $A\beta_j = \mathbf{0}$ 对所有 j 成立。反向执行上述计算：

$$AB = [A\beta_1 \mid \cdots \mid A\beta_s] = [\mathbf{0} \mid \cdots \mid \mathbf{0}] = O.$$

因此 $AB = O$ 。



命题

n 阶矩阵 A, B , 若 $AB = O$, 则 $r(A) + r(B) \leq n$

例 3: 秩的不等式

命题

n 阶矩阵 A, B , 若 $AB = O$, 则 $r(A) + r(B) \leq n$

证明思路

- B 的列向量是 $AX = O$ 的解
- $r(B) \leq \dim(\ker(A)) = n - r(A)$
- 故 $r(A) + r(B) \leq n$

几何意义

- $r(A)$: 像空间维度
- $r(B)$: 零空间中的向量组秩
- 维度约束:
 $\dim(\ker(A)) + \dim(\text{im}(A)) = n$

历史注记

该不等式是 Sylvester 秩不等式的一个特例, 由 James Joseph Sylvester 在 19 世纪提出。

AI 应用

在推荐系统中, 该不等式用于分析用户-物品评分矩阵的潜在因子维度。

例 3 证明：秩不等式 $r(A) + r(B) \leq n$

Step 1. 列空间落入零空间

由例 2 已知 $AB = O$ 当且仅当

$$\text{Col}(B) \subseteq \ker A.$$

因此

$$\dim \text{Col}(B) \leq \dim \ker A.$$

Step 2. 维数公式

对线性映射 $A: \mathbb{F}^n \rightarrow \mathbb{F}^m$ 用秩-零化度定理：

$$\dim \ker A + \dim \text{Im } A = n \implies \dim \ker A = n - r(A).$$

代入上式得

$$r(B) = \dim \text{Col}(B) \leq n - r(A),$$

即

$$r(A) + r(B) \leq n. \quad \square$$

命题

对任意实矩阵 A , 有 $r(A^T A) = r(A)$

例 4: $A^T A$ 的秩定理

命题

对任意实矩阵 A , 有 $r(A^T A) = r(A)$

证明思路

- 证明 $AX = O$ 与 $A^T AX = O$ 同解
- 若 $AX = O$, 则 $A^T AX = O$
- 若 $A^T AX = O$, 则
 $X^T A^T AX = 0 \rightarrow \|AX\|^2 = 0$
 $\rightarrow AX = O$

几何意义

- $A^T A$ 是 Gram 矩阵, 度量列向量的内积
- 秩相等意味着信息保持
- 正交投影保持秩不变

应用价值

该定理是最小二乘法和主成分分析 (PCA) 的数学基础。

核心引理

$$A\mathbf{x} = \mathbf{0} \iff A^T A\mathbf{x} = \mathbf{0}.$$

一旦成立, 两矩阵的零空间相同, 维数相等, 再由秩-零化度定理即得

$$r(A^T A) = r(A).$$

($\Rightarrow$) 方向

若 $A\mathbf{x} = \mathbf{0}$, 则

$$A^T A\mathbf{x} = A^T (A\mathbf{x}) = A^T \mathbf{0} = \mathbf{0}.$$

($\Leftarrow$) 方向

设 $A^T A \mathbf{x} = \mathbf{0}$ 。左乘 $\mathbf{x}^T$ 得

$$\mathbf{x}^T A^T A \mathbf{x} = 0 \Rightarrow (A \mathbf{x})^T (A \mathbf{x}) = 0 \Rightarrow \|A \mathbf{x}\|^2 = 0.$$

在实数域内范数非负, 故

$$A \mathbf{x} = \mathbf{0}.$$

秩等式

$$\dim \ker(A^T A) = \dim \ker A \Rightarrow n - r(A^T A) = n - r(A) \Rightarrow r(A^T A) = r(A). \quad \square$$

科学计算

- 数值线性代数中的秩估计
- 矩阵分解的稳定性分析
- 病态方程组的正则化

图像处理

- 图像压缩的低秩近似
- 视频监控中的背景建模
- 医学图像重建

机器学习

- 低秩矩阵补全（推荐系统）
- 神经网络的正则化约束
- 特征选择的秩准则

量子计算

- 量子态的低秩表示
- 量子门操作的秩分析
- 量子纠错码设计

历史意义

秩理论从 19 世纪发展至今，已成为线性代数的核心概念，在科学与工程各个领域发挥着重要作用。

基本形式

$$Ax = b \quad (b \neq 0)$$

导出组概念

将 b 替换为 0 得到齐次方程组：

$$Ax = 0$$

称为原方程组的导出组。

历史注记

- 非齐次方程研究源于物理学中的强迫振动问题
- 傅里叶在热传导研究中系统化此类方程
- 现代应用广泛于工程和 AI 领域

几何视角

非齐次方程的解空间是齐次解空间的平移，形成仿射空间。

Python 表示

```
import numpy as np
# 构建非齐次方程组
A = np.array([[a11, ..., a1n], ..., [am1, ..., amn]])
b = np.array([b1, ..., bm])
```

基本性质

- 性质 1: 两个解的差是导出组的解

$$A(X_1 - X_2) = AX_1 - AX_2 = b - b = 0$$

- 性质 2: 解与导出组解的和仍是解

$$A(X_1 + X_3) = AX_1 + AX_3 = b + 0 = b$$

几何解释

- 解空间是齐次解空间的平移
- 任意两个解的差落在齐次解空间中
- 解空间是仿射空间而非向量空间

物理类比

- 齐次解: 自由振动模式
- 特解: 外力驱动响应
- 通解: 总响应 = 强迫响应 + 自由振动

AI 应用

在神经网络中，非齐次方程对应有偏置的线性变换，影响模型的表达能力。

通解定理

非齐次方程组的通解可表示为：

$$X = X^* + k_1 \xi_1 + k_2 \xi_2 + \cdots + k_{n-r} \xi_{n-r}$$

- X^* : 特解 (particular solution)
- ξ_i : 导出组的基础解系
- k_i : 任意常数

证明思路

- 任意解 X 与特解 X^* 的差是导出组的解
- 故可表示为基础解系的线性组合
- 重组得到通解形式

历史发展

- 该结构由达朗贝尔在振动研究中发现
- 拉格朗日将其推广到一般线性系统
- 现代成为线性系统理论基石

Step 1. 差分法

任取方程组的一个解 $\mathbf{x}$ 。令

$$\mathbf{z} = \mathbf{x} - \mathbf{x}^*.$$

则

$$A\mathbf{z} = A(\mathbf{x} - \mathbf{x}^*) = \mathbf{b} - \mathbf{b} = \mathbf{0}.$$

故 $\mathbf{z}$ 是导出组的解。

Step 2. 基础解系展开

由于 $\{\xi_i\}$ 是导出组的基，存在唯一系数 k_i 使得

$$\mathbf{z} = \sum_{i=1}^{n-r} k_i \xi_i.$$

代回即得

$$\mathbf{x} = \mathbf{x}^* + \sum_{i=1}^{n-r} k_i \xi_i.$$

Step 3. 反向验证

对任意选取的 k_i , 令

$$\mathbf{x} = \mathbf{x}^* + \sum_{i=1}^{n-r} k_i \boldsymbol{\xi}_i,$$

则

$$A\mathbf{x} = A\mathbf{x}^* + \sum_{i=1}^{n-r} k_i A\boldsymbol{\xi}_i = \mathbf{b} + \mathbf{0} = \mathbf{b}.$$

故该形式覆盖所有解, 定理得证。



Python 实现

```
def general_solution(A, b):  
    # 求特解  
    particular = np.linalg.lstsq(A, b,  
                                rcond=None)[0]  
    # 求齐次基础解系  
    null_basis = null_space(A)  
    return particular, null_basis
```

问题

求解:

$$\begin{cases} x_1 - x_2 - x_3 + x_4 = 0 \\ x_1 - x_2 + x_3 - 3x_4 = 1 \\ x_1 - x_2 - 2x_3 + 3x_4 = -1/2 \end{cases}$$

例 1: 非齐次方程组求解

问题

求解:

$$\begin{cases} x_1 - x_2 - x_3 + x_4 = 0 \\ x_1 - x_2 + x_3 - 3x_4 = 1 \\ x_1 - x_2 - 2x_3 + 3x_4 = -1/2 \end{cases}$$

增广矩阵变换

$$\begin{pmatrix} 1 & -1 & -1 & 1 & 0 \\ 1 & -1 & 1 & -3 & 1 \\ 1 & -1 & -2 & 3 & -1/2 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & -1 & 0 & -1 & 1/2 \\ 0 & 0 & 1 & -2 & 1/2 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

解的分析

- $\text{rank}(A) = \text{rank}(A|b) = 2$
- $n = 4, r = 2$
- 自由变量: x_2, x_4
- 无穷多解

特解与基础解系

- 特解: $X^* = (1/2, 0, 1/2, 0)^T$
- 基础解系:

$$\xi_1 = (1, 1, 0, 0)^T, \quad \xi_2 = (1, 0, 2, 1)^T$$

通解表达式

$$X = \begin{pmatrix} 1/2 \\ 0 \\ 1/2 \\ 0 \end{pmatrix} + k_1 \begin{pmatrix} 1 \\ 1 \\ 0 \\ 0 \end{pmatrix} + k_2 \begin{pmatrix} 1 \\ 0 \\ 2 \\ 1 \end{pmatrix}$$

几何意义

- 特解: 仿射空间的基点
- 基础解系: 空间的方向向量
- 通解: 二维平面上的所有点

AI 应用

在优化问题中，通解结构解释了为什么正则化能够约束解空间，避免过拟合。

命题

设 $\alpha_1, \dots, \alpha_r$ 是 $AX = 0$ 的基础解系, β 是 $AX = b$ ($b \neq 0$) 的特解, 证明 $\beta, \beta + \alpha_1, \dots, \beta + \alpha_r$ 线性无关。

例 2：线性无关性证明

命题

设 $\alpha_1, \dots, \alpha_r$ 是 $AX = 0$ 的基础解系, β 是 $AX = b$ ($b \neq 0$) 的特解, 证明 $\beta, \beta + \alpha_1, \dots, \beta + \alpha_r$ 线性无关。

证明思路

- 设线性组合等于零
- 应用矩阵 A 得到约束条件
- 利用基础解系线性无关性
- 推导所有系数为零

几何解释

- 向量组构成仿射框架
- 线性无关保证坐标系良好定义
- 在优化中用于构造搜索方向

应用价值

该性质在迭代优化算法中很重要, 确保搜索方向的线性无关性。

Python 验证

```
def check_independence(alpha, beta):  
    # 构造向量组  
    vectors = np.column_stack([beta] + [beta + a for a in  
    alpha.T])  
    # 检查秩是否等于 r+1  
    return np.linalg.matrix_rank(vectors) == len(alpha)+1
```

例 2 线性无关性证明

Step 1. 设组合为零

取标量 $k_0, k_1, \dots, k_r$ 使得

$$k_0 \beta + \sum_{i=1}^r k_i (\beta + \alpha_i) = \mathbf{0}.$$

整理得

$$(k_0 + k_1 + \dots + k_r) \beta + \sum_{i=1}^r k_i \alpha_i = \mathbf{0}. \quad (1)$$

Step 2. 作用 A 得约束

将 (1) 左乘 A :

$$(k_0 + \dots + k_r) A \beta + \sum_{i=1}^r k_i A \alpha_i = (k_0 + \dots + k_r) \mathbf{b} = \mathbf{0}.$$

因 $\mathbf{b} \neq \mathbf{0}$, 必有

$$k_0 + k_1 + \dots + k_r = 0. \quad (2)$$

Step 3. 利用基础解系无关性

把 (2) 代回 (1) 得

$$\sum_{i=1}^r k_i \alpha_i = \mathbf{0}.$$

因 $\{\alpha_i\}$ 线性无关, 故

$$k_1 = \cdots = k_r = 0.$$

再由 (2) 得 $k_0 = 0$ 。因此所有系数为零, 向量组 $\mathcal{B}$ 线性无关。



工程领域

- 结构力学中的荷载分析
- 电路理论中的输入响应
- 控制系统中的强迫响应

数据科学

- 机器学习中的偏置项
- 推荐系统中的用户偏好
- 图像处理中的对比度调整

计算机科学

- 计算机图形学的仿射变换
- 数字信号处理中的滤波
- 网络分析中的流量分配

物理科学

- 量子力学中的外加场效应
- 电磁学中的源项处理
- 热力学中的热源分析

历史意义

非齐次方程组理论从 18 世纪发展至今，已成为描述自然现象和工程系统的基本数学工具。

步骤 1：矩阵化简

对系数矩阵 A 进行初等行变换，化为行最简形矩阵

$$A \rightarrow \text{行最简形}$$

- ：高斯消元法，源于《九章算术》，高斯系统化
- ：现代数值计算中使用 LU 分解、QR 分解等优化算法

步骤 2：方程重写

写出等价方程组，区分自由变量和非自由变量

$$\begin{cases} x_1 = \cdots \\ x_2 = \cdots \\ \vdots \\ x_r = \cdots \end{cases}$$

步骤 3：基向量构造

令自由变量取标准基值，求解得基础解向量

- ：几何意义：构建解空间的坐标系
- ：每个基向量对应一个自由度方向

步骤 4：基础解系形成

将所有基础解向量组合成基础解系

$$\xi_1, \xi_2, \dots, \xi_{n-r}$$

齐次方程组通解

$$X = k_1 \xi_1 + k_2 \xi_2 + \cdots + k_{n-r} \xi_{n-r}$$

- k_i : 任意常数 (参数)
- ξ_i : 基础解系向量
- 几何意义: 过原点的线性子空间

Python 实现

```
def homogeneous_solution(A):  
    null_basis = null_space(A)  
    # 生成通解函数  
    return lambda params:  
        null_basis @ params
```

非齐次方程组通解

$$X = X_0 + k_1 \xi_1 + k_2 \xi_2 + \cdots + k_{n-r} \xi_{n-r}$$

- X_0 : 特解 (基点)
- 几何意义: 仿射空间 (平移子空间)
- 应用: 物理学中的特解 + 通解模式

MATLAB 实现

```
% 使用反斜杠运算符求特解  
x_particular = A\b  
% 求零空间基  
null_basis = null(A)
```

秩判定定理

对于方程组 $Ax = b$:

- $r(A) \neq r(A|b) \iff$ 无解
 - 几何: b 不在 A 的列空间中
 - 应用: 机器学习中的不可行问题
- $r(A) = r(A|b) = n \iff$ 唯一解
 - 几何: 超平面交于一点
 - 应用: 适定问题, 良好条件数
- $r(A) = r(A|b) < n \iff$ 无穷多解
 - 几何: 解空间为仿射子空间
 - 应用: 欠定问题, 需要正则化

历史背景

- 秩概念由 Sylvester 于 19 世纪引入
- 判定定理由 Rouché 和 Capelli 完善
- 现代成为线性代数核心理论

Python 验证

```
def check_solvability(A, b):  
    rank_A = np.linalg.matrix_rank(A)  
    rank_Ab = np.linalg.matrix_rank(  
        np.column_stack((A, b)))  
    return rank_A, rank_Ab
```

科学与工程

- 结构力学: 刚度矩阵求解
- 电路分析: 基尔霍夫定律
- 流体力学: Navier-Stokes 方程离散化
- 量子力学: 薛定谔方程数值解

计算机科学

- 计算机图形学: 仿射变换
- 数值模拟: 有限元方法
- 密码学: 线性密码分析
- 网络分析: 图论与邻接矩阵

数据科学与 AI


- 机器学习: 线性回归与正则化
- 图像处理: 计算机视觉中的投影几何
- 推荐系统: 矩阵分解与补全
- 自然语言处理: 词向量线性代数

经济学与社会科学

- 投入产出分析: Leontief 模型
- 计量经济学: 联立方程模型
- 社交网络: 影响力传播建模

历史意义与未来展望

线性方程组理论从古代《九章算术》发展到现代数值计算，始终是科学技术的数学基石，在人工智能和大数据时代继续发挥重要作用。



学习建议

- 理解几何直观，而不仅是代数操作
- 掌握数值实现，而不仅是理论推导
- 联系实际应用，而不仅是抽象概念
- 关注历史发展，而不仅是现代形式

Q&A

谢谢