

第七章：二次型

戴一冕

南开大学 计算机学院

2025.08.26

- § 7.1 n 元实二次型及其标准形
- § 7.2 正定二次型
- § 7.3 用正交变换化二次型为标准形

- § 7.1 n 元实二次型及其标准形
- § 7.2 正定二次型
- § 7.3 用正交变换化二次型为标准形

定义 1

n 个实变元的实系数二次齐次函数

$$\begin{aligned} f(x_1, x_2, \dots, x_n) = & a_{11}x_1^2 + 2a_{12}x_1x_2 + 2a_{13}x_1x_3 + \dots + 2a_{1n}x_1x_n \\ & + a_{22}x_2^2 + 2a_{23}x_2x_3 + \dots + 2a_{2n}x_2x_n \\ & + a_{33}x_3^2 + \dots + 2a_{3n}x_3x_n \\ & + \dots \\ & + a_{nn}x_n^2 \end{aligned}$$

称为实数域上的一个 n 元二次型, 简称实二次型。

- 把变元交叉项 $2a_{ij}x_ix_j (i < j)$ 写成对称的两项之和 $a_{ij}x_ix_j + a_{ji}x_jx_i$, 其中 $(a_{ij} = a_{ji})$ 。

二次型的几何起源

二次型的研究，最早可以追溯到古希腊数学家对**圆锥曲线**的研究。

- **笛卡尔的解析几何**: 17 世纪，**笛卡尔**用代数方程描述几何曲线，一个一般的圆锥曲线方程就是二元二次型： $ax^2 + bxy + cy^2 + dx + ey + f = 0$ 。其中， $ax^2 + bxy + cy^2$ 部分就是二次型，它决定了曲线的形状和朝向。
- **欧拉与拉格朗日**: 18 世纪，**欧拉** 和 **拉格朗日**将此推广到三维空间，用于分类二次曲面（如椭球体、双曲面）。他们发现，通过旋转坐标系可以消去方程中的交叉项（如 xy, xz, yz ），从而得到一个“标准方程”，使曲面的几何特性一目了然。
- **配方法思想**: 拉格朗日提出的“配方法”，将几何上的“旋转对齐”思想转化为纯粹的代数技巧，并将其推广到任意 n 元二次型。

核心思想

研究二次型，最初是为了理解和分类几何对象的形状。而“化为标准形”，就是为这些几何对象寻找一个最自然的坐标系，使其方程最简洁、性质最清晰。

二次型的矩阵表示

$$\begin{aligned} f(x_1, \dots, x_n) &= a_{11}x_1^2 + a_{12}x_1x_2 + \cdots + a_{1n}x_1x_n \\ &\quad + a_{21}x_2x_1 + a_{22}x_2^2 + \cdots + a_{2n}x_2x_n \\ &\quad + \cdots \\ &\quad + a_{n1}x_nx_1 + a_{n2}x_nx_2 + \cdots + a_{nn}x_n^2 \\ &= \sum_{i=1}^n \sum_{j=1}^n a_{ij}x_ix_j \end{aligned}$$

将系数排成一个矩阵:

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}$$

- 称为实二次型 $f(x_1, \dots, x_n)$ 的矩阵。
- 显然 A 为 (实) 对称矩阵。

记 $X = (x_1, x_2, \dots, x_n)^T$ 。对于上述对称矩阵 A , 有

$$\begin{aligned} X^T A X &= (x_1, \dots, x_n) \begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \\ &= (x_1, \dots, x_n) \begin{pmatrix} a_{11}x_1 + \cdots + a_{1n}x_n \\ \vdots \\ a_{n1}x_1 + \cdots + a_{nn}x_n \end{pmatrix} \\ &= a_{11}x_1^2 + a_{12}x_1x_2 + \cdots + a_{nn}x_n^2 \\ &= \sum_{i=1}^n \sum_{j=1}^n a_{ij}x_i x_j \end{aligned}$$

$$f(x_1, x_2, \dots, x_n) = \sum_{i=1}^n \sum_{j=1}^n a_{ij}x_i x_j = X^T A X$$

任给一个二次型, 可唯一确定一个对称矩阵。反之, 任给一个对称矩阵, 可唯一确定一个二次型。即二次型与对称矩阵之间是一一对应关系。

- 对称矩阵 A 称为二次型 $f(x_1, \dots, x_n)$ 的矩阵。
- $f(x_1, \dots, x_n)$ 称为对称矩阵 A 的二次型。
- A 的秩就称为二次型的秩。

二次型：所有复杂函数的“二阶近似”

在微积分中，任何一个足够光滑的多元函数 $F(X)$ 在一个极值点 X_0 附近，都可以通过泰勒展开近似为一个二次函数。其二次项部分，就是一个二次型。

$$F(X) \approx F(X_0) + \nabla F(X_0)^T (X - X_0) + \frac{1}{2} (X - X_0)^T H (X - X_0)$$

其中 H 是函数在该点的**海森矩阵**，它是一个对称矩阵。

- **核心作用**: 这个二次型 $(X - X_0)^T H (X - X_0)$ 描述了该点附近的**局部曲率**。
- **机器学习与优化**: 在训练神经网络等机器学习模型时，本质上是在一个极高维的“损失函数”曲面上寻找最低点。梯度下降法只利用一阶信息（坡度），而牛顿法等更强大的优化算法，则利用二阶信息（曲率），即海森矩阵对应的二次型，来更快速、更准确地找到最小值点。

计算联系

二次型的理论，尤其是判断其正定性（下一节内容），是现代大规模优化算法的理论基础。

例

写出二次型 $f(x_1, x_2, x_3) = 3x_1^2 + x_2^2 - x_3^2 + 2x_1x_2 - x_1x_3 + 4x_2x_3$ 的矩阵。

例

写出二次型 $f(x_1, x_2, x_3) = 3x_1^2 + x_2^2 - x_3^2 + 2x_1x_2 - x_1x_3 + 4x_2x_3$ 的矩阵。

矩阵为:

$$A = \begin{pmatrix} 3 & 1 & -\frac{1}{2} \\ 1 & 1 & 2 \\ -\frac{1}{2} & 2 & -1 \end{pmatrix}$$

注意

虽然对于非对称矩阵 $B = \begin{pmatrix} 3 & 2 & -1 \\ 0 & 1 & 4 \\ 0 & 0 & -1 \end{pmatrix}$, 也有 $X^T B X = 3x_1^2 + x_2^2 - x_3^2 + 2x_1x_2 - x_1x_3 + 4x_2x_3$ 。但是矩阵 B 并不是对称矩阵, 也不是该二次型的矩阵。

例

写出以矩阵 $\begin{pmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix}$ 为矩阵的二次型。

例

写出以矩阵 $\begin{pmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix}$ 为矩阵的二次型。

二次型为：

$$f(x_1, x_2, x_3) = x_2^2 + 2x_1x_3$$

该二次型的秩为 3。

定理

n 元实二次型 X^TAX 可经坐标变换 $X = CY$ (C 为可逆实矩阵) 化为二次型 Y^TBY , 其中 $B = C^TAC$ 。

定义 2: 合同矩阵

设 A, B 是数域 $\mathbb{F}$ 上的 n 阶矩阵, 若存在 $\mathbb{F}$ 上的可逆矩阵 C , 使得 $B = C^TAC$ 成立, 则称 A 与 B 是合同矩阵。

合同性质

1. **反身性:** 任意矩阵 A 都与自身合同。
2. **对称性:** 若 A 与 B 合同, 则 B 与 A 合同。
3. **传递性:** 若 A 与 B 合同, B 与 C 合同, 则 A 与 C 合同。

定义

只含变元平方项的二次型:

$$f = d_1x_1^2 + d_2x_2^2 + \cdots + d_nx_n^2$$

称为二次型的标准形。

- 其矩阵是主对角线上元素为 $d_1, d_2, \dots, d_n$ 的对角矩阵。
- 它的秩等于对角矩阵主对角线上非零元的个数, 即标准形中非零平方项的个数。

标准形揭示了二次型的“本质形态”

将二次型化为标准形，等价于旋转和缩放坐标轴，直到与二次曲面的主轴对齐。标准形中的系数，直接告诉我们其几何或统计学上的关键信息。

- **几何判定:** 对于 $f(x, y) = k_1x^2 + k_2y^2 = 1$,
 - 若 k_1, k_2 **全为正**，等高线是一个**椭圆**，函数图像是一个向上开口的碗状（抛物面）。
 - 若 k_1, k_2 **一正一负**，等高线是**双曲线**，函数图像是一个**马鞍面**。
 - 这对应了在优化中判定一个点是**极小值点**还是**鞍点**。
- **统计学与数据分析:** 在统计学中，一个多元正态分布的密度函数核心是一个二次型 $(X - \mu)^T \Sigma^{-1} (X - \mu)$.
 - 将其化为标准形，相当于找到了数据分布的**主轴** (Principal Axes)，即数据变化最剧烈的方向（这与 PCA 紧密相关）。
 - 标准形中的系数（协方差矩阵特征值的倒数）则反映了数据在这些主轴方向上的**离散程度**（方差）。

例 1: 拉格朗日配方法

化二次型为标准形并求所用的坐标变换。

$$f(x_1, x_2, x_3) = x_1^2 + 6x_1x_2 + 8x_2^2 - 2x_2x_3 - 5x_3^2$$

例 1: 拉格朗日配方法

化二次型为标准形并求所用的坐标变换。

$$f(x_1, x_2, x_3) = x_1^2 + 6x_1x_2 + 8x_2^2 - 2x_2x_3 - 5x_3^2$$

$$\begin{aligned} f &= (x_1^2 + 6x_1x_2) + 8x_2^2 - 2x_2x_3 - 5x_3^2 \\ &= (x_1 + 3x_2)^2 - 9x_2^2 + 8x_2^2 - 2x_2x_3 - 5x_3^2 \\ &= (x_1 + 3x_2)^2 - x_2^2 - 2x_2x_3 - 5x_3^2 \\ &= (x_1 + 3x_2)^2 - (x_2^2 + 2x_2x_3) - 5x_3^2 \\ &= (x_1 + 3x_2)^2 - (x_2 + x_3)^2 + x_3^2 - 5x_3^2 \\ &= (x_1 + 3x_2)^2 - (x_2 + x_3)^2 - 4x_3^2 \end{aligned}$$

做坐标变换 $\begin{cases} y_1 = x_1 + 3x_2 \\ y_2 = x_2 + x_3 \\ y_3 = x_3 \end{cases}$, 反解得 $\begin{cases} x_1 = y_1 - 3y_2 + 3y_3 \\ x_2 = y_2 - y_3 \\ x_3 = y_3 \end{cases}$ 。

标准形为 $f = y_1^2 - y_2^2 - 4y_3^2$ 。

1. 若二次型含有 x_i 的平方项, 则先把含有 x_i 的乘积项集中, 然后配方。再对其余的变量同样进行, 直到都配成平方项为止, 经过非退化线性变换, 就得到标准形。
2. 若不含有平方项, 但是 $a_{ij} \neq 0$ ($i \neq j$), 则先作可逆线性变换

$$\begin{cases} x_i = y_i + y_j \\ x_j = y_i - y_j \\ x_k = y_k \end{cases} \quad (k \neq i, j)$$

化二次型为含有平方项的二次型, 然后再按第 1 步中的方法配方。

化二次型 $f(x_1, x_2, x_3) = 2x_1x_2 + 2x_1x_3 - 6x_2x_3$ 为标准形, 并求所用坐标变换。

例 2: 拉格朗日配方法

1. 做坐标变换 $\begin{cases} x_1 = y_1 + y_2 \\ x_2 = y_1 - y_2 \\ x_3 = y_3 \end{cases}$, 得

$$\begin{aligned} f &= 2(y_1 + y_2)(y_1 - y_2) + 2(y_1 + y_2)y_3 - 6(y_1 - y_2)y_3 \\ &= 2y_1^2 - 2y_2^2 - 4y_1y_3 + 8y_2y_3 \end{aligned}$$

2. 配方

$$\begin{aligned} f &= 2(y_1^2 - 2y_1y_3) - 2y_2^2 + 8y_2y_3 \\ &= 2(y_1 - y_3)^2 - 2y_3^2 - 2y_2^2 + 8y_2y_3 \\ &= 2(y_1 - y_3)^2 - 2(y_2^2 - 4y_2y_3) - 2y_3^2 \\ &= 2(y_1 - y_3)^2 - 2(y_2 - 2y_3)^2 + 8y_3^2 - 2y_3^2 \\ &= 2(y_1 - y_3)^2 - 2(y_2 - 2y_3)^2 + 6y_3^2 \end{aligned}$$

3. 最终标准形为 $f = 2w_1^2 - 2w_2^2 + 6w_3^2$ 。

规范形

系数为 +1 或 -1 的标准形称为规范形。

$$z_1^2 + \cdots + z_t^2 - z_{t+1}^2 - \cdots - z_r^2$$

定理 2 (惯性定理)

在秩为 r 的 n 元实二次型的标准形中, 正平方项的个数 t 是唯一确定的, 从而负平方项的个数 $r - t$ 也是唯一确定的。

- t 称为正惯性指数, $r - t$ 为负惯性指数。
- 两个 n 元实二次型等价 $\Leftrightarrow$ 它们有相同的秩和正惯性指数。

定理 3

秩为 r 的 n 阶对称矩阵 A 必合同于对角形矩阵。即存在满秩矩阵 C , 使得

$$C^T A C = \text{diag}(d_1, d_2, \dots, d_r, 0, \dots, 0)$$

其中 $d_i \neq 0$ 。

- 任何可逆矩阵 C 都可以写成一系列初等矩阵的乘积。
- $C^T A C = F_m^T \cdots F_1^T A F_1 \cdots F_m$ 。
- 这意味着可以用一系列的合同变换 (成对地进行相同的行、列初等变换) 把 A 化为对角形。
- 在对 A 做初等行变换的同时, 如果对单位矩阵 E 只做同样顺序的列变换, 则 E 最终会化为变换矩阵 C 。

1. 写出二次型的矩阵 A 。
2. 构造增广矩阵 $\begin{pmatrix} A \\ E \end{pmatrix}$ 。
3. 对 A 施行成对的初等行、列变换 (合同变换) 将其化为对角阵 D , 在此过程中, 对 A 的行变换也同样作用于 E 所在的下半部分; 对 A 的列变换则不影响 E 。(注: 更常见的做法是对 $\begin{pmatrix} A & E \end{pmatrix}$ 进行操作, 对 A 做行变换时也对 E 做, 对 A 做列变换时则不影响 E , 最终得到 $\begin{pmatrix} D & (C^T)^{-1} \end{pmatrix}$ 。
4. 最终得到 $\begin{pmatrix} D \\ C^T \end{pmatrix}$ 或 $\begin{pmatrix} D \\ C \end{pmatrix}$ 的形式, 从中得到对角阵 D 和变换矩阵 C 。
5. 最终标准形为 $f = d_1 y_1^2 + \cdots + d_r y_r^2$, 坐标变换为 $X = CY$ 。

- **核心概念:** 实二次型, 标准形, 规范形, 秩, 正/负惯性指数, 符号差。
- **核心关系:**
 - 二次型与对称矩阵之间是一一对应关系。
 - 矩阵的合同关系是一种等价关系。
 - 惯性定理保证了标准形中正负项个数的唯一性。
- **核心方法 (重点):**
 - 拉格朗日配方法。
 - 合同变换法化二次型为标准形。

Q&A

- § 7.1 n 元实二次型及其标准形
- **§ 7.2 正定二次型**
- § 7.3 用正交变换化二次型为标准形

定义 1

若对任意 $X \neq 0$, 恒有 $X^TAX > 0$, 则实二次型 X^TAX 称为正定二次型。正定二次型的矩阵称为正定矩阵, 记为 $A > 0$ 。

- 已知: n 元二次型的标准形为

$$X^TAX = d_1x_1^2 + d_2x_2^2 + \cdots + d_nx_n^2。$$

- 仅当所有 n 个系数 $d_i > 0 (i = 1, 2, \dots, n)$ 时, 它才是正定的。

* 坐标变换 (非退化线性替换) 保持二次型的正定性不变。

非标准形的二次型是否正定的判定方法

定理 1: n 元实二次型正定 $\Leftrightarrow$ 它的正惯性指数等于 n 。例如 $f(x, y, z) = x^2 + 4y^2 + 16z^2$ 为正定二次型。

多维空间中的“碗形”函数

正定二次型 $f(X) = X^T A X$ 是对一元函数 $f(x) = ax^2 (a > 0)$ 的多维推广。

- **几何形状**: 正如 $f(x) = ax^2$ 是一条开口向上的抛物线, 且在 $x = 0$ 处有唯一最小值一样, 一个正定二次型的图像是一个开口向上的碗形, 在点 $X = 0$ 处有唯一的全局最小值。

物理起源: 稳定平衡态

正定性的概念最早源于物理学中对**稳定平衡**的研究。

- 18 世纪, **拉格朗日**在其经典著作《分析力学》中研究力学系统的平衡点。他指出, 一个系统的势能函数 $V(X)$ 在某一点达到平衡, 如果该点是势能的**极小值点**, 则该平衡是**稳定的**。
- 判断一个点是否为极小值点的关键, 就是看函数在该点附近的二阶近似 (即二次型) 是否为**正定**的。正定的势能面就像一个碗底, 一个微受扰动的小球总会滚回最低点, 因此是稳定的。

- **推论 1:** n 元实二次型正定的必要条件是 $|A| > 0$ 。
- **推论 2:** n 阶实对称矩阵 $A > 0 \Leftrightarrow A$ 与阶单位矩阵 E 合同。
- **推论 3:** n 阶实对称矩阵 $A > 0 \Leftrightarrow$ 存在可逆实矩阵 C 使得 $A = C^T C$ 。

定义 2: 顺序主子式

矩阵 $A = (a_{ij})_{n \times n}$ 的子阵 $A_k = \begin{pmatrix} a_{11} & \cdots & a_{1k} \\ \vdots & \ddots & \vdots \\ a_{k1} & \cdots & a_{kk} \end{pmatrix}$ 称为 A 的顺序主子阵。 $|A_1|, |A_2|, \dots, |A_n|$ 称为 A 的顺序主子式。

定理 2 (Sylvester's Criterion)

n 元实二次型正定 $\Leftrightarrow$ 它的矩阵 $A = (a_{ij})$ 的顺序主子式都大于零。

机器学习中的凸优化

现代机器学习的核心任务通常是最小化一个复杂的损失函数 $L(w)$ 。如果该函数的**海森矩阵**在全域都是**正定**的，那么这个损失函数就是**严格凸函数**。

- **黄金特性**: 凸函数形如一个“碗”，它保证了通过梯度下降等方法找到的任意一个局部最小值，都必定是**全局最小值**。
- **判定需求**: 因此，判断一个矩阵（海森矩阵）是否正定，对于分析优化问题的难度、保证算法能收敛到最优解至关重要。Sylvester 判别法为此提供了高效的代数工具。

数值计算中的 Cholesky 分解

在工程和科学计算中，求解形如 $Ax = b$ 的线性方程组是家常便饭。

- 如果矩阵 A 是对称正定的，那么它可以被唯一地分解为 $A = LL^T$ 的形式，其中 L 是一个下三角矩阵。这称为 **Cholesky 分解**。
- **巨大优势**：求解 $LL^Tx = b$ 只需两次简单的三角回代，其计算速度大约是标准高斯消元法的**两倍**，且**数值稳定性**极高。在进行大规模仿真（如有限元分析）时，判定矩阵正定并使用 Cholesky 分解是首选的高效算法。

必要性: 设 $f(x_1, \dots, x_n) = X^T A X$ 正定, 则 $|A| > 0$ 。

考察 A 的 (对称) 顺序主子阵 $A_k (k = 1, \dots, n-1)$ 对应的二次型:

$$\begin{aligned} f_k(x_1, \dots, x_k) &= (x_1, \dots, x_k) A_k \begin{pmatrix} x_1 \\ \vdots \\ x_k \end{pmatrix} \\ &= \sum_{i=1}^k \sum_{j=1}^k a_{ij} x_i x_j \\ &= f(x_1, \dots, x_k, 0, \dots, 0) \end{aligned}$$

对任意 $(x_1, \dots, x_k) \neq 0$ 时, 必有 $(x_1, \dots, x_k, 0, \dots, 0) \neq 0$ 。而 $f(x_1, \dots, x_n) = X^T A X$ 正定, 因此

$$f_k(x_1, \dots, x_k) = f(x_1, \dots, x_k, 0, \dots, 0) > 0$$

即 $f_k(x_1, \dots, x_k)$ 正定, 从而其矩阵的行列式 $|A_k| > 0$ 。

充分性: 用数学归纳法。

- 当 $n = 1$ 时, 二次型为 $a_{11}x_1^2$, 显然当 $a_{11} > 0$ 时正定。
- 设对 $n - 1$ 定理结论成立, 对于 n , 由于 $|A_1| = a_{11} > 0$, 故可进行初等变换, 将 A 的第一列的 $-\frac{a_{1j}}{a_{11}}$ 倍加到第 j 列上, 同时将第一行的 $-\frac{a_{1j}}{a_{11}}$ 倍加到第 j 行 ($j = 2, \dots, n$) 上得到合同矩阵:

$$P^T A P = \begin{pmatrix} a_{11} & 0 & \cdots & 0 \\ 0 & b_{22} & \cdots & b_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & b_{n2} & \cdots & b_{nn} \end{pmatrix} = \begin{pmatrix} a_{11} & 0 \\ 0 & B \end{pmatrix}$$

其中 $B = (b_{ij})$ 是 $n - 1$ 阶矩阵。

则坐标变换 $X = PY$ 化二次型为:

$$f = a_{11}y_1^2 + \sum_{i,j=2}^n b_{ij}y_iy_j = a_{11}y_1^2 + g(y_2, \dots, y_n)$$

由于变换不改变顺序主子式的符号规律, 并且:

$$|A_j| = \begin{vmatrix} a_{11} & \cdots & a_{1j} \\ \vdots & \ddots & \vdots \\ a_{j1} & \cdots & a_{jj} \end{vmatrix} = \begin{vmatrix} a_{11} & 0 & \cdots & 0 \\ 0 & b_{22} & \cdots & b_{2j} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & b_{j2} & \cdots & b_{jj} \end{vmatrix} = a_{11} \begin{vmatrix} b_{22} & \cdots & b_{2j} \\ \vdots & \ddots & \vdots \\ b_{j2} & \cdots & b_{jj} \end{vmatrix} = a_{11}|B_{j-1}|$$

而 $a_{11} > 0$ 且 $|A_j| > 0$, 因此二次型 g 的各阶顺序主子式也大于 0。由归纳法假设, $g(y_2, \dots, y_n)$ 正定。对于任意的 $X \neq 0$, 有

$Y = P^{-1}X \neq 0$, 则 y_1 和 $(y_2, \dots, y_n)$ 至少有一个不为零。因此恒有 $f = a_{11}y_1^2 + g(y_2, \dots, y_n) > 0$, 即 $f = X^TAX$ 为正定二次型。

判别下面二次型是否正定。

$$f(x_1, x_2, x_3) = 5x_1^2 + x_2^2 + 5x_3^2 + 4x_1x_2 - 8x_1x_3 - 4x_2x_3$$

判别下面二次型是否正定。

$$f(x_1, x_2, x_3) = 5x_1^2 + x_2^2 + 5x_3^2 + 4x_1x_2 - 8x_1x_3 - 4x_2x_3$$

解: $f(x_1, x_2, x_3)$ 的矩阵为 $A = \begin{pmatrix} 5 & 2 & -4 \\ 2 & 1 & -2 \\ -4 & -2 & 5 \end{pmatrix}$ 。它的顺序主子式:

$$\bullet |A_1| = 5 > 0$$

$$\bullet |A_2| = \begin{vmatrix} 5 & 2 \\ 2 & 1 \end{vmatrix} = 1 > 0$$

$$\bullet |A_3| = |A| = \begin{vmatrix} 5 & 2 & -4 \\ 2 & 1 & -2 \\ -4 & -2 & 5 \end{vmatrix} = 1 > 0$$

故上述二次型是正定的。

定义 3

若对任意 $X \neq 0$, 恒有 $X^T A X < 0$, 则实二次型 $X^T A X$ 称为负定二次型。负定二次型的矩阵称为负定矩阵, 记为 $A < 0$ 。* 坐标

变换 (非退化线性替换) 保持二次型的负定性不变。

n 元实二次型 $f = X^T A X$ 负定 $\Leftrightarrow$

- 它的负惯性指数等于 n 。
- $-A > 0$ 。
- (霍尔维茨定理) A 的奇数阶顺序主子式为负, 而偶数阶顺序主子式为正。即:

$$(-1)^k |A_k| = (-1)^k \begin{vmatrix} a_{11} & \cdots & a_{1k} \\ \vdots & \ddots & \vdots \\ a_{k1} & \cdots & a_{kk} \end{vmatrix} > 0, \quad (k = 1, 2, \dots, n)$$

必要条件

n 元实二次型负定的必要条件是 $(-1)^n |A| > 0$ 。

判定下面二次型是正定二次型还是负定二次型。

$$f = -5x^2 - 6y^2 - 4z^2 + 4xy + 4xz$$

判定下面二次型是正定二次型还是负定二次型。

$$f = -5x^2 - 6y^2 - 4z^2 + 4xy + 4xz$$

解: f 的矩阵为 $A = \begin{pmatrix} -5 & 2 & 2 \\ 2 & -6 & 0 \\ 2 & 0 & -4 \end{pmatrix}$ 。顺序主子式:

- $|A_1| = -5 < 0$
- $|A_2| = \begin{vmatrix} -5 & 2 \\ 2 & -6 \end{vmatrix} = 26 > 0$
- $|A_3| = |A| = -80 < 0$

奇数阶为负, 偶数阶为正。因此 f 为负定二次型。

二次型 $f = X^TAX$ 正定

充要条件:

- 对任意 $X \neq 0$, 恒有 $X^TAX > 0$ 。
- A 的正惯性指数等于 n 。
- A 合同于单位矩阵 E 。
- 存在可逆矩阵 C 使得 $A = C^TC$ 。
- A 的顺序主子式全大于零。
- A 的特征值全大于零。

二次型 $f = X^TAX$ 半正定

充要条件:

- 对任意 $X \neq 0$, 恒有 $X^TAX \geq 0$ 。
- A 的正惯性指数等于 $r(A)$ (或负惯性指数等于 0)。
- 存在矩阵 P 使得 $A = P^TP$ 。
- A 的所有主子式全大于或等于零。
- A 的特征值全大于或等于零。

- 正定二次型和正定矩阵的定义
- 判定二次型 (实对称矩阵) 正定的判定方法和相关结论 (重点)
- 负定二次型和负定矩阵及其充要条件
- 了解半正定、半负定、不定二次型的概念

思考题

设 A, B 分别为 m 阶, n 阶正定矩阵, 试判定分块矩阵

$$C = \begin{pmatrix} A & 0 \\ 0 & B \end{pmatrix}$$

是否为正定矩阵。

结论

C 是正定的。

- 设 $z^T = (x^T, y^T)$ 为 $m + n$ 维向量, 其中 x, y 分别是 m 维和 n 维列向量。
- 若 $z \neq 0$, 则 x, y 不同时为零向量。
- 于是:

$$\begin{aligned} z^T C z &= (x^T, y^T) \begin{pmatrix} A & 0 \\ 0 & B \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} \\ &= x^T A x + y^T B y \end{aligned}$$

- 因为 A, B 正定, 且 x, y 不同时为 0, 所以 $x^T A x \geq 0$ 和 $y^T B y \geq 0$ 至少有一个大于 0。
- 因此 $z^T C z > 0$ 。
- 且 C 是实对称阵, 故 C 为正定矩阵。

Q&A

- § 7.1 n 元实二次型及其标准形
- § 7.2 正定二次型
- **§ 7.3 用正交变换化二次型为标准形**

定理

设 T 是欧氏空间的一个线性变换, 则下述条件等价:

1. T 是正交变换;
2. T 保持向量的内积不变;
3. T 把标准正交基变为标准正交基;
4. T 在标准正交基下的矩阵是正交矩阵.

正交矩阵

正交矩阵满足 $A^T A = E$, 则 $A^T = A^{-1}$ 。

等价于:

- 求正交矩阵 C , 使得

$$C^TAC = C^{-1}AC = \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{pmatrix}$$

条件

- A 的特征根都是实数;
- A 有 n 个实特征向量构成的标准正交向量组, 使 A 化为对角形.

“最好”的坐标变换：只旋转，不形变

拉格朗日配方法化标准形，其变换 $X = CY$ (C 仅可逆) 可能包含拉伸、错切等复杂形变。而正交变换 $X = CY$ (C 为正交矩阵) 是一种“刚性变换”，它在计算机科学中具备无可比拟的优势。

- **保持几何结构 (不扭曲):** 正交变换的本质是**旋转**或**反射**。它保持了空间中所有向量的长度和它们之间的夹角。这意味着数据点云的“形状”在变换后没有被扭曲，我们只是换了一个观察角度。这对于（如 PCA 等）需保持度量关系的分析至关重要。
- **完美的数值稳定性:** 正交矩阵的逆矩阵就是其转置 ($C^{-1} = C^T$)。这让求逆运算变得简单精确，避免了普通矩阵求逆的巨大计算量和舍入误差。在任何需要高精度计算的场合，基于正交变换的算法（如 QR 分解、SVD）都是首选。

核心理想

寻找一个正交变换来化简二次型，就是寻找一个纯粹的“旋转”，使我们能正对着二次曲面的“主轴”进行观察，从而以最简单、最保真的方式理解其形态。

一、对称矩阵的性质

- **说明:** 本节所提到的对称矩阵, 除非特别说明, 均指实对称矩阵.
- **复习:**
 - 复数 $z = a + bi$ ($a, b \in \mathbb{R}$), 若 $b = 0$, 则 z 就是一个实数.
 - 复平面中向量 $\vec{OZ}$ 的模叫做复数的模 (或绝对值), 记做 $|z| = |a + bi| = \sqrt{a^2 + b^2}$.
 - $\bar{z} = a - bi$ 称为 z 的共轭复数; $z \cdot \bar{z} = |z|^2 = a^2 + b^2$.
 - 设复向量 $X = (x_1, x_2, \dots, x_n)$ 则 $\bar{X} = (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_n)$ 称为向量 X 的共轭向量.

定理 1

对称矩阵的特征根必为实数.

证明: 设复数 λ 为对称矩阵 A 的特征值, X 为对应特征向量, 则

$$AX = \lambda X, \quad X \neq 0.$$

于是

$$A\bar{X} = \overline{AX} = (\overline{AX}) = \overline{\lambda X} = \bar{\lambda}\bar{X}.$$

因此

$$\bar{X}^T AX = (\bar{X}^T A^T)X = (A\bar{X})^T X = (\bar{\lambda}\bar{X})^T X = \bar{\lambda}\bar{X}^T X \quad (1)$$

$$\bar{X}^T AX = \bar{X}^T (AX) = \bar{X}^T \lambda X = \lambda \bar{X}^T X \quad (2)$$

(2)-(1), 得

$$(\lambda - \bar{\lambda})\bar{X}^T X = 0.$$

但因为 $X \neq 0$, 所以

$$\bar{X}^T X = \sum_{i=1}^n \bar{x}_i x_i = \sum_{i=1}^n |x_i|^2 \neq 0,$$

可得

$$(\lambda - \bar{\lambda}) = 0, \quad \text{即} \quad \lambda = \bar{\lambda}.$$

由此可得 λ 是实数.

定理 1 的意义

由于对称矩阵的特征根 λ_i 为实数, 所以齐次线性方程组

$$(\lambda_i E - A)X = 0 \quad (*)$$

是实系数方程组, 由 $|\lambda_i E - A| = 0$ 知 $(*)$ 必有实的基础解系, 从而对应的特征向量可以取实向量.

定理 2

设 λ_0 是 n 阶对称阵 A 的 k 重特征根, 则 A 的对应于 λ_0 的特征子空间 V_{λ_0} 的维数恰为 k , 即齐次线性方程组

$$(\lambda_0 E - A)X = 0$$

的基础解系恰有 k 个解向量.

- 由定理 1,2 可知: n 阶对称矩阵一定有 n 个线性无关的实特征向量, 从而它必相似于实对角矩阵.

定理 3

设 λ_1 与 λ_2 是对称矩阵的互异特征根, X_1, X_2 分别是 A 的属于它们的特征向量, 则 X_1, X_2 正交。(即 $X_1^T X_2 = 0$)

证明:

$$\lambda_1 X_1 = AX_1, \quad \lambda_2 X_2 = AX_2, \quad \lambda_1 \neq \lambda_2$$

$\because A$ 对称, $A = A^T$,

$$\therefore \lambda_1 X_1^T = (\lambda_1 X_1)^T = (AX_1)^T = X_1^T A^T = X_1^T A,$$

于是

$$\begin{aligned} \lambda_1 X_1^T X_2 &= X_1^T A X_2 = X_1^T (\lambda_2 X_2) = \lambda_2 X_1^T X_2 \\ &\Rightarrow (\lambda_1 - \lambda_2) X_1^T X_2 = 0. \end{aligned}$$

$\because \lambda_1 \neq \lambda_2$,

$$\therefore X_1^T X_2 = 0 \quad \text{即} \quad X_1 \text{与} X_2 \text{正交.}$$

定理 4 (实对称矩阵的谱定理 / 主轴定理)

对任意 n 阶**实对称矩阵** A , **一定存在**正交矩阵 C , 使得

$$C^T A C = C^{-1} A C = \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{pmatrix}$$

其中 $\lambda_1, \lambda_2, \dots, \lambda_n$ 是 A 的全部特征根.

证明: 设 A 的互不相等的特征值为 $\lambda_1, \lambda_2, \dots, \lambda_s$, 它们的重数依次为 $r_1, r_2, \dots, r_s$

$$(r_1 + r_2 + \dots + r_s = n)$$

谱定理：几何、代数与数据的统一

线性代数中最深刻的结果之一

“实对称矩阵必可被正交对角化”这一定理，也称**谱定理** (Spectral Theorem) 或 **主轴定理**，是纯数学与应用科学的桥梁。

- **历史背景 (19 世纪, 柯西/雅可比等)**: 源于天体力学、弹性力学和二次曲面研究。它完美地连接了：**代数性质** (矩阵对称) $\Leftrightarrow$ **几何结论** (存在一组正交的主轴)。
- **现代应用：主成分分析 (PCA)**: 这是谱定理在数据科学中的最核心应用。
 - 数据集的**协方差矩阵** C 必定是实对称矩阵。
 - 谱定理保证： C 必可被正交对角化。
 - 这组正交基 (C 的特征向量) 就是**主成分**：它们是数据中方差最大且相互独立（正交）的方向。
 - 变换到此基下（即 PCA），就完成了对数据的“信息浓缩”和降维。

应用联系

从分析材料应力、人脸识别到数据降维，本质都是利用谱定理，为复杂系统寻找一组最能揭示其内在结构的正交“主轴”。

- 根据定理 1(对称矩阵的特征值为实数) 和定理 2(k 重特征根对应解空间维数恰为 k) 可得:
- A 对应特征根 $\lambda_i (i = 1, 2, \dots, s)$ 恰有 r_i 个线性无关的实特征向量, 把它们正交化、单位化 (对于单根只单位化), 即得 A 的对应于 λ_i 的 r_i 个单位正交的特征向量. 于是共 s 个得到 r_i 个标准正交组, 且向量总数恰为 n .
- 由定理 3 知对应于不同特征根的特征向量正交, 故这 n 个单位特征向量两两正交, 从而构成一个标准正交组. 以它们为列向量 (按对应特征根顺序) 构成正交矩阵 C , 则:

续上页, 可得对角矩阵 Λ :

$$C^{-1}AC = C^TAC = \Lambda = \begin{pmatrix} \lambda_1 & & & & & & 0 \\ & \ddots & & & & & \\ & & \lambda_1 & & & & \\ & & & \lambda_2 & & & \\ 0 & & & & \ddots & & \\ & & & & & \ddots & \\ & & & & & & \lambda_s \end{pmatrix}$$

注

其中对角线上的元素 $\lambda_1, \dots, \lambda_s$ 分别是出现 $r_1, \dots, r_s$ 次的特征值。

1. 对称矩阵的性质 (重点)

1. 特征值为实数;
2. 属于不同特征值的特征向量正交;
3. 特征值的重数和与之对应的线性无关的特征向量的个数相等;
4. 必存在正交矩阵, 将其化为对角矩阵, 且对角矩阵对角元素即为特征值.

2. 利用正交矩阵将对称阵化为对角阵的步骤 (重点)

1. 求特征值;
2. 找特征向量;
3. 将特征向量 (按特征根分组) 正交化;
4. 最后单位化.

二、用正交矩阵将对称矩阵对角化的方法

定理 5

任一个 n 元实二次型

$$f(x_1, x_2, \cdots x_n) = X^T A X, \quad (A^T = A)$$

必存在正交变换 $X = CY (C^T = C^{-1})$ 使其化为标准形

$$f(x_1, x_2, \cdots x_n) = \lambda_1 y_1^2 + \lambda_2 y_2^2 + \cdots + \lambda_n y_n^2 = Y^T \Lambda Y$$

其中 $\Lambda = \text{diag}(\lambda_1, \lambda_2 \cdots \lambda_n)$, $\lambda_1, \lambda_2 \cdots \lambda_n$ 是对称矩阵 A 的全部特征根.

二次型 $X^T A X$ 为正定二次型的充要条件是特征根全大于零.

根据上述结论, 利用正交变换将实二次型化为标准形的步骤为:

1. 写出实二次型 $f = X^T A X$ 对应的对称矩阵 A ;
2. 求矩阵 A 的全部特征根;
3. 对 A 的每个特征根 λ_i 求齐次线性方程组 $(\lambda_i E - A)X = 0$ 的基础解系——即求其线性无关特征向量, 并将它们正交化、单位化;
4. 用这些单位化后的向量作为列项量顺次构成矩阵 C , 则 C 为正交矩阵, 且 $C^T A C = C^{-1} A C = \Lambda$ 为对角形矩阵.

将下面的二次型通过正交变换 $X = PY$ 化为标准形.

$$f(x_1, x_2, x_3) = 17x_1^2 + 14x_2^2 + 14x_3^2 - 4x_1x_2 - 4x_1x_3 - 8x_2x_3$$

解:

1. 写出二次型对应的矩阵 $A = \begin{pmatrix} 17 & -2 & -2 \\ -2 & 14 & -4 \\ -2 & -4 & 14 \end{pmatrix}$
2. 求其特征值

$$|\lambda E - A| = \begin{vmatrix} \lambda - 17 & 2 & 2 \\ 2 & \lambda - 14 & 4 \\ 2 & 4 & \lambda - 14 \end{vmatrix} = (\lambda - 9)(\lambda - 18)^2$$

从而得特征值 $\lambda_1 = 9, \lambda_2 = \lambda_3 = 18$.

(3) 求特征向量并将其单位化、正交化

- 将 $\lambda_1 = 9$ 代入 $(\lambda E - A)X = 0$, 得基础解系 $\xi_1 = (1/2, 1, 1)^T$
- 将 $\lambda_2 = \lambda_3 = 18$ 代入 $(\lambda E - A)X = 0$, 得基础解系 $\xi_2 = (-2, 1, 0)^T$, $\xi_3 = (-2, 0, 1)^T$.

将特征向量正交化 (注: 此时分为两组)

- 取 $\alpha_1 = \xi_1$
- $\alpha_2 = \xi_2$
- $\alpha_3 = \xi_3 - \frac{\langle \alpha_2, \xi_3 \rangle}{\langle \alpha_2, \alpha_2 \rangle} \alpha_2$

得正交向量组:

$$\alpha_1 = (1/2, 1, 1)^T, \alpha_2 = (-2, 1, 0)^T, \alpha_3 = (-2/5, -4/5, 1)^T$$

将正交向量组单位化:

$$\eta_i = \frac{\alpha_i}{\|\alpha_i\|}, \quad (i = 1, 2, 3)$$

得

$$\eta_1 = \begin{pmatrix} 1/3 \\ 2/3 \\ 2/3 \end{pmatrix}, \eta_2 = \begin{pmatrix} -2/\sqrt{5} \\ 1/\sqrt{5} \\ 0 \end{pmatrix}, \eta_3 = \begin{pmatrix} -2/\sqrt{45} \\ -4/\sqrt{45} \\ 5/\sqrt{45} \end{pmatrix}$$

(4) 构成矩阵 P

$$P = \begin{pmatrix} 1/3 & -2/\sqrt{5} & -2/\sqrt{45} \\ 2/3 & 1/\sqrt{5} & -4/\sqrt{45} \\ 2/3 & 0 & 5/\sqrt{45} \end{pmatrix}$$

于是所求正交变换为 $X = PY$ 化二次型为标准型

$$f = 9y_1^2 + 18y_2^2 + 18y_3^2.$$

思考题

三种化二次型为标准形的方法有何异同？

- ☐ 用配方法化二次型为标准形
- ☐ 用合同变换法化二次型为标准形
- ☐ 用正交变换法化二次型为标准形

- 将一个二次型化为标准形, 可用正交变换法, 也可用拉格朗日配方法, 或合同变换法, 这取决于问题要求.
- 若要求找出一个正交矩阵, 无疑应使用正交变换法; 如果只需要找出一个可逆的线性变换, 那么各种方法都可以使用.
- 正交变换法的好处是有固定的步骤, 但计算量通常较大; 通常情况合同变换法方法计算量较小, 过程也相对简单明确; 但如果二次型中变量个数较少, 使用拉格朗日配方法反而比较简单.

需要注意的是

使用不同的方法, 所得到的标准形可能不相同, 但标准形中含有的项数必定相同 (项数等于所给二次型的秩); 同时正惯性指数和负惯性指数相同.

本节重点

- **用正交矩阵将对称矩阵对角化的方法 (重点)**

Q&A

THANKS